

论文思想与算法总结

Theory of Continual Learning Against Data Poisoning Attacks

面向公式阅读困难的中文总览

2026 年 7 月 9 日

目录

1	一句话总览	3
2	论文在解决什么问题	3
2.1	连续学习的正常目标	3
2.2	投毒为什么在 CL 中更危险	3
3	攻击分类：论文的攻防地图	4
4	主线一：为什么有些攻击一定防不住	4
4.1	核心直觉	4
4.2	frequent shifted 攻击为什么致命	5
4.3	frequent unbounded non-shifted 为什么也防不住	5
5	主线二：少量强攻击的 T2T 防御	5
5.1	T2T 想解决什么	5
5.2	T2T 检测分数的逻辑	6
5.3	T2T 算法流程	6
5.4	T2T 的理论保证	6
5.5	T2T 的适用边界	7
6	主线三：频繁有界零均值攻击的鲁棒特征防御	7
6.1	为什么不再靠检测	7
6.2	攻击者为什么会打敏感方向	7
6.3	对角化后的直观图像	7
6.4	鲁棒特征防御算法流程	7
6.5	protected set 是什么	8
6.6	鲁棒特征防御的理论保证	8
7	两种防御的对比	9

目录	2
8 这篇论文真正提供的算法思想	9
8.1 不是单一防御，而是先分清攻击条件	9
8.2 把 CL 投毒看成在线 minimax	9
8.3 把正则化矩阵从“防遗忘”升级为“抗攻击”	9
9 实验结论怎么理解	10
10 论文假设与局限	10
11 读这篇论文的推荐顺序	10
12 最终总结	11

1 一句话总览

这篇论文研究的问题是：连续学习模型按任务序列不断训练时，如果攻击者在训练数据里投毒，正则化式连续学习什么时候一定防不住，什么时候还能设计出有证明保证的防御。

论文给出的核心答案可以压缩成三句话：

- 如果攻击很频繁，并且攻击能持续改变数据均值，或者每次零均值攻击的方差预算越来越大，那么正则化式连续学习没有一般性的收敛保证。
- 如果攻击次数很少，即使单次攻击很强，也可以用 task-to-task verification (T2T) 检测最近两个任务的异常更新，并通过回滚避免攻击长期累积。
- 如果攻击很频繁但每次有界且零均值，不能主要靠检测，而要把正则化矩阵设计成鲁棒的特征方向防御，让攻击者无法集中打最脆弱方向。

2 论文在解决什么问题

2.1 连续学习的正常目标

连续学习 (continual learning, CL) 中，任务按时间到来：

$$1, 2, \dots, T.$$

第 t 个任务有数据 D_t 。模型训练完第 $t-1$ 个任务后得到参数 w_{t-1} ，然后只用当前任务数据和一个正则化项更新到 w_t 。

论文讨论的核心算法族是正则化式 CL：

$$w_t \in \arg \min_w \left\{ \frac{1}{n_t} \sum_{z \in D_t} \ell(w, z) + \frac{1}{2} \|w - w_{t-1}\|_{H_t}^2 \right\}.$$

这条公式的直觉是：

- 第一项让模型适应当前任务；
- 第二项让模型不要离旧模型太远；
- H_t 是防御者最主要的控制旋钮，它决定哪些参数方向更不容易被新数据拉动。

2.2 投毒为什么在 CL 中更危险

普通训练中，投毒影响一次训练过程；CL 中，攻击可以沿时间反复插入。一次被污染的更新会变成下次训练的起点，所以攻击影响会继续传播。

论文把攻击者看成强对手：它知道当前模型、当前数据和历史信息，并能在任务 t 的数据中加入扰动

$$\eta_t = (\eta_{x,t}, \eta_{y,t}).$$

其中 $\eta_{x,t}$ 是输入特征扰动， $\eta_{y,t}$ 是标签扰动。理论模型先允许两者都存在；后面为了得到清晰证明，很多结论在线性回归中只分析 label poisoning。

3 攻击分类：论文的攻防地图

论文把攻击能力分成三个维度。

维度	两种情况	含义
频率	frequent / infrequent	攻击任务数 K 是否随总任务数 T 线性增长。frequent 表示 $K = \Theta(T)$, infrequent 表示 $K = O(1)$ 或很少。
强度	bounded / unbounded	单次攻击预算 M 是否随 T 增大。unbounded 表示攻击方差或能量可达到 $\Omega(T)$ 量级。
模式	shifted / non-shifted	shifted 会改变扰动的条件均值；non-shifted 满足 $\mathbb{E}[\tilde{\eta}_t \mid \text{历史信息}] = 0$, 也就是平均方向不偏, 但方差可以变大。

由这三个维度组合，论文得到下面的可防御性结论。

频率	强度	模式	论文结论
frequent	bounded	shifted	无一般收敛保证。持续均值偏移会让模型长期学到错误方向。
frequent	unbounded	shifted 或 non-shifted	无一般收敛保证。即使均值为 0, 巨大方差也能压过数据本身信号。
infrequent	unbounded	shifted 或 non-shifted	可以防。论文提出 T2T 检测加回滚，最终误差可收敛。
frequent	bounded	non-shifted	可以缓解。论文提出鲁棒特征正则化，通过 minimax 选择 H_t , 加快收敛。

4 主线一：为什么有些攻击一定防不住

4.1 核心直觉

正则化式 CL 的本质是一个加权折中：

$$\text{新模型} \approx \text{吸收当前数据} + \text{保留旧模型}.$$

如果模型完全不吸收当前数据，它学不到新任务；如果模型吸收当前数据，它也会吸收投毒。攻击者正是利用这个矛盾。

4.2 frequent shifted 攻击为什么致命

shifted attack 的关键不是“噪声大”，而是“方向有偏”。如果每个任务都被加入同方向偏移 Δ ，模型每次学习当前任务时都会把这个偏移当成真实规律的一部分。

论文用一维线性回归反例说明这个事实。递推可以写成：

$$w_t - w^* = c_t(w_{t-1} - w^*) + (1 - c_t)(\varepsilon_t + \eta_t),$$

其中 w^* 是真实参数， c_t 表示保留旧模型的比例。

如果攻击者总是取 $\eta_t = \Delta$ ，那么模型误差的均值会被推向 Δ 。这说明只要攻击频繁且有固定方向，最终误差不可能趋于 0。

4.3 frequent unbounded non-shifted 为什么也防不住

non-shifted 攻击虽然均值为 0，但可以增加方差。若每次攻击方差预算 $M_T = \Omega(T)$ ，那么随机扰动的平均方向不偏也没用，因为波动太大。

直觉上，模型最终误差包含很多历史噪声的加权和：

$$w_T - w^* = \text{初始误差残留} + \sum_{s=1}^T \beta_{s,T}(\varepsilon_s + \tilde{\eta}_s).$$

当 $\tilde{\eta}_s$ 的方差随 T 增大时，这个和的方差不会消失，最终风险也不会收敛到 0。

这就是 Theorem 3.1 的意义：不是某个算法设计得不好，而是在这些攻击条件下，整个正则化式 CL 框架都没有统一保证。

5 主线二：少量强攻击的 T2T 防御

5.1 T2T 想解决什么

T2T 面对的场景是：攻击次数少，但单次攻击可以很强，甚至是 shifted attack。直觉上，少量强攻击应该能被检测出来；难点是不能只看当前更新大小。

只看

$$\|w_t - w_{t-1}\|$$

会有误判，因为大更新可能来自三种原因：

- 当前任务真的和旧任务不同；
- 当前任务被投毒；
- 过去被投毒的影响正在通过模型状态传播。

T2T 的想法是比较两个相邻更新：

$$w_t - w_{t-1}, \quad w_{t-1} - w_{t-2}.$$

它先用两个投影矩阵把这两个更新变到可比较空间，再相减。设计目标是消掉更早历史状态 w_{t-2} 的影响，只保留最近两个任务的信息。

5.2 T2T 检测分数的逻辑

检测分数可以抽象理解为：

$$d_t = \|\text{处理后的当前更新} - \text{处理后的上一更新}\|.$$

论文中的 $D_t^1, D_t^2, A_t, B_t, C_t$ 都是为了实现一件事：

$$D_t^1 A_t = D_t^2 B_t.$$

这条关系保证两次更新里共同的历史项会在相减时抵消。

因此，T2T 不是简单地看“模型有没有变大”，而是看“最近两个任务造成的局部变化是否异常”。

5.3 T2T 算法流程

用不含复杂公式的方式，T2T 算法可以写成：

1. 维护最近三个模型 w_{t-2}, w_{t-1}, w_t ，以及对应的正则化矩阵和 Hessian 近似。
2. 当前任务到来后，先按正则化式 CL 得到候选模型 w_t 。
3. 根据当前和上一任务的局部曲率，构造两个历史抵消投影 D_t^1, D_t^2 。
4. 计算检测分数

$$d_t = \|D_t^1(w_t - w_{t-1}) - D_t^2(w_{t-1} - w_{t-2})\|.$$

5. 如果 d_t 超过阈值，就认为最近任务中有投毒，拒绝或回滚对应更新；否则接受当前模型。

5.4 T2T 的理论保证

在线性回归、平方损失、label poisoning 的理论设置下，论文给出阈值 θ_t ，使得良性任务的检测分数以高概率不会超过阈值。

若任务数据足够 informative，且使用论文给出的历史信息正则化矩阵，则 T2T 防御后最终风险满足大意上的界：

$$\mathcal{R}(w_T) = O\left(\frac{K^2}{\epsilon T}\right).$$

其中：

- K 是攻击任务数量；
- T 是总任务数量；
- ϵ 是允许误报概率相关参数。

所以当 $K = O(1)$ 时，风险会随 T 增大而下降到 0。若 K 增长太快， K^2/T 不再趋于 0，T2T 的收敛保证也会消失。

5.5 T2T 的适用边界

T2T 适合少量强攻击，不适合频繁攻击。原因很简单：如果几乎每个任务都可疑，检测加回滚会丢掉太多任务，模型就没有足够干净数据可学。

此外，T2T 依赖 Hessian 或 Hessian 近似。在线性模型中这很自然；在深度网络中通常需要用对角近似、低秩近似或经验 Fisher 近似。

6 主线三：频繁有界零均值攻击的鲁棒特征防御

6.1 为什么不再靠检测

这一部分面对的是 frequent + bounded + non-shifted attack。攻击几乎每轮都可能出现，但单次预算有限，而且平均方向为 0。

如果继续用 T2T 检测，系统可能不断拒绝任务；但这些任务中仍然包含有用学习信号。因此论文换了思路：不问“哪个任务坏了”，而是问“哪些特征方向最容易被攻击放大”。

6.2 攻击者为什么会打敏感方向

在正则化更新中，当前数据扰动如何影响参数，取决于一个敏感矩阵。直观上：

$$\text{参数偏移} \approx \text{敏感矩阵} \times \text{数据扰动}.$$

如果某个方向的放大倍数最大，攻击者就会把有限预算集中投到这个方向。这就是论文中“最大奇异方向”的意义。

普通正则化只考虑怎么减少干净数据下的遗忘；鲁棒特征防御则额外考虑攻击者会主动寻找最脆弱方向。

6.3 对角化后的直观图像

论文为了得到闭式解，假设任务 Hessian 可以同时对角化。这样参数空间可以拆成很多互不干扰的方向：

$$u_1, u_2, \dots, u_p.$$

每个方向 u_j 有两个关键量：

- γ_j^t ：当前任务在这个方向上提供了多少数据曲率，也就是有多少有效学习信号；
- λ_j^t ：防御者在这个方向设置的正则化强度，也就是对这个方向踩多重的刹车。

攻击者会偏好那些“数据弱、误差大、容易被扰动放大”的方向。防御者则要提高这些方向的保护力度。

6.4 鲁棒特征防御算法流程

鲁棒特征防御可以按下面流程理解：

1. 对当前任务的 Hessian 做特征分解，得到方向 u_j 和曲率 γ_j^t 。

2. 估计上一轮每个方向的风险 $\mathcal{R}_j^{t-1}$ 。
3. 假设攻击者会在预算 M 内选择最坏方向，建立在线 minimax 问题。
4. 解这个 minimax 问题，得到每个方向的最优正则化强度 λ_j^t 。
5. 把这些 λ_j^t 重新组成正则化矩阵

$$H_t = U \text{diag}(\lambda_1^t, \dots, \lambda_p^t) U^\top.$$

6. 用这个 H_t 执行当前任务的正则化更新。

6.5 protected set 是什么

protected set 是论文中最有用的概念之一。它不是人工指定的特征集合，而是由 minimax 解自动选出来的一组脆弱方向。

这些方向满足：如果防御者不特别处理，攻击者最可能把预算投到这里。因此最优防御会让这些方向的攻击敏感度被压到同一水平，避免某个单一方向成为最大短板。

可以把它理解为一种水位平衡：

- 原来某些方向特别低，攻击者最容易从那里突破；
- 防御者把正则化资源优先放到这些低洼方向；
- 最终 protected set 中的方向达到相近的最坏敏感度。

6.6 鲁棒特征防御的理论保证

在 protected set 长期稳定、Hessian 可同时对角化等假设下，论文证明鲁棒特征防御的最终风险具有更好的上界。关键区别是：

- 普通正则化的攻击项容易被单个最坏方向控制；
- 鲁棒特征防御把最坏敏感度分摊到 protected set，避免单个小曲率方向主导风险。

这并不表示攻击完全无效，而是表示在 bounded non-shifted frequent attack 下，模型仍能以可控速度收敛，并且比普通正则化更稳。

7 两种防御的对比

对比项	T2T 防御	鲁棒特征防御
目标场景	少量强攻击, 允许 shifted 或 unbounded	频繁但有界、零均值攻击
核心动作	检测异常任务并拒绝/回滚	不拒绝任务, 重新设计 H_t
主要信号	相邻两次模型更新的投影差	Hessian 特征方向上的攻击敏感度
关键思想	消掉历史影响, 只看最近异常	压低最脆弱方向, 分散最坏风险
理论条件	线性回归、平方损失、informative tasks、噪声阈值控制	线性回归、non-shifted bounded、Hessian 可同时对角化、预算上界
主要限制	攻击频繁时会丢太多任务	不能处理 shifted 或 unbounded 攻击的不可防御性

8 这篇论文真正提供的算法思想

8.1 不是单一防御, 而是先分清攻击条件

论文最重要的贡献不是说“某个算法万能”, 而是明确告诉我们:

不同攻击条件需要不同防御, 且有些条件根本不能防。

这比只提出一个经验算法更强, 因为它给出理论边界。

8.2 把 CL 投毒看成在线 minimax

防御者每轮选 H_t , 攻击者每轮选扰动 η_t 。防御者想让最终风险小, 攻击者想让最终风险大。这就是在线零和博弈:

$$\min_{H_t} \max_{\eta_t} \text{最终风险或其近似上界.}$$

T2T 是在少量强攻击场景下用检测把异常任务排除; 鲁棒特征防御是在频繁弱攻击场景下直接解 minimax 正则化。

8.3 把正则化矩阵从“防遗忘”升级为“抗攻击”

传统 EWC 或相关正则化方法主要用 H_t 表示旧任务重要性, 目标是避免灾难性遗忘。论文的关键升级是: H_t 还应该考虑攻击者会如何利用当前任务的敏感方向。

因此, H_t 不只是记忆旧知识的工具, 也是控制攻击传播路径的工具。

9 实验结论怎么理解

论文实验主要验证两个直觉：

- 对少量 **shifted** 攻击，T2T 的检测分数会在攻击附近出现明显峰值；有时整体测试准确率看不出异常，但局部更新分数能暴露问题。
- 对频繁有界 **non-shifted** 攻击，普通正则化和记忆回放方法可能被敏感特征方向拖慢；鲁棒特征防御能更稳定地下降风险。

实验不是替代理论证明，而是说明理论机制在 CIFAR、预训练 ViT 线性头、CNN 等设置中也有可观察效果。

10 论文假设与局限

需要注意，这篇论文的证明不是无条件适用于所有深度学习系统。

- 严格理论主要建立在线性回归和平方损失上；对深度网络的解释依赖线性化、NTK 或只训练线性头的近似。
- T2T 需要 Hessian 或 Hessian 近似，高维模型中计算和存储会成为问题。
- T2T 的收敛界含 K^2/T ，所以它要求攻击任务数量不能太快增长。
- 鲁棒特征防御需要知道或估计攻击预算 M 。如果预算估得过大，模型可能过度保守；估得过小，则防御不足。
- 鲁棒特征防御的闭式解依赖 Hessian 同时对角化、protected set 稳定等假设，实际神经网络中通常只能近似使用。
- 对 frequent shifted attack 或 frequent unbounded non-shifted attack，论文给出的结论是无一般收敛保证，不应该期待简单调参解决。

11 读这篇论文的推荐顺序

如果只想先理解论文思想，建议按下面顺序读：

1. 先看 Table 1，理解攻击分类和可防御性边界。
2. 看公式 (2)，理解所有方法都围绕正则化更新和 H_t 展开。
3. 看 Theorem 3.1，接受“有些频繁攻击不能防”的结论。
4. 看 Algorithm 1 和 Section 4，理解 T2T 为什么比较两个相邻更新。
5. 看 Section 5 的 minimax 解释，理解攻击者为什么集中打最大敏感方向。
6. 最后再回到附录证明，逐步看 Taylor 展开、伪逆、SVD、KKT 等细节。

12 最终总结

这篇论文的攻防逻辑可以概括为：

问题	论文回答
攻击什么时候不可防？	频繁 shifted 攻击和频繁 unbounded 攻击会破坏正则化 CL 的收敛机制。
少量强攻击怎么办？	用 T2T 比较相邻更新，消去历史影响，检测异常任务并回滚。
频繁弱攻击怎么办？	不再主要检测任务，而是在 Hessian 特征方向上做 mini-max 正则化，保护最脆弱方向。
论文最大的启发是什么？	CL 安全不能只看单轮鲁棒性，必须分析攻击如何沿时间传播，并根据攻击频率、强度、均值偏移决定防御策略。

参考文献

[1] Yiting Hu and Lingjie Duan. *Theory of Continual Learning Against Data Poisoning Attacks*. arXiv:2606.29841, 2026.