

论文公式与证明导读

Theory of Continual Learning Against Data Poisoning Attacks

阅读笔记与证明讲解

2026 年 7 月 7 日

目录

1 先给结论：这篇论文到底在证明什么	3
2 背景知识补充	3
2.1 连续学习与灾难性遗忘	3
2.2 正则化式 CL 更新	4
2.3 数据投毒的三个维度	4
2.4 为什么会出现 Hessian、伪逆和混合二阶导	4
2.5 线性回归设置	5
3 命题 2.4 / 附录命题 A.1：攻击目标的近似公式	5
3.1 结论形式	5
3.2 证明拆解	6
4 定理 3.1：为什么有些攻击根本防不住	7
4.1 定理含义	7
4.2 一维反例	7
4.3 frequent shifted 攻击	7
4.4 frequent unbounded non-shifted 攻击	8
5 T2T 防御：少量但强攻击的检测与证明	8
5.1 检测分数的设计	8
5.2 引理 4.1：为什么这个分数能隔离最近两个任务	9
5.3 证明关键：构造 $D_t^1 A_t = D_t^2 B_t$	9
5.4 检测阈值：Lemma 4.3	10
5.5 Theorem 4.4：最终误差界	10
6 频繁有界零均值攻击：鲁棒特征防御	11
6.1 为什么不能继续靠检测	11
6.2 线性模型中的 minimax 递推	11
6.3 对角化假设与每个方向的风险	12

目录	2
6.4 Proposition 5.2: 最优正则化的水位结构	12
6.5 Proposition 5.2 的证明	13
6.6 Theorem 5.3: 为什么鲁棒特征防御更快	14
6.7 和普通正则化 / EWC 型基线的比较	15
7 实验部分怎么读	16
8 读公式的路线图	16
9 这篇论文的假设与局限	16
10 一句话总结	17

1 先给结论：这篇论文到底在证明什么

这篇论文研究的是：在连续学习（continual learning, CL）中，模型按任务序列 $1, 2, \dots, T$ 依次训练。如果攻击者在部分任务的数据里加入投毒扰动，正则化式连续学习方法什么时候一定防不住，什么时候可以设计出有证明保证的防御。

论文的三条主线如下。

1. **不可防御边界**。如果攻击很频繁，并且攻击能改变数据均值（shifted attack），或者虽然**不改变均值但每次攻击方差预算随 T 线性增长**，那么任何形如

$$w_t \in \arg \min_w \left\{ \frac{1}{n_t} \sum_{z \in D_t} \ell(w, z) + \frac{1}{2} \|w - w_{t-1}\|_{H_t}^2 \right\}$$

的正则化式 CL 方法都无法保证最终误差收敛到 0。

2. **少量但可能无限强的攻击可以用检测加回滚防御**。对于只**攻击有限多个任务但单次攻击强度可以很大的情形**，论文设计了 task-to-task verification (T2T) 检测分数 d_t 。它通过两个相邻更新 $w_t - w_{t-1}$ 与 $w_{t-1} - w_{t-2}$ 的投影组合，消去历史状态 w_{t-2} 的影响。最终证明：**只要攻击任务数 K 不随 T 线性增长**，最终误差可达到

$$\mathcal{R}(w_T) = O\left(\frac{K^2}{\epsilon T}\right)$$

量级。

3. **频繁但有界、零均值攻击需要鲁棒特征正则化**。如果几乎每个任务都可能被投毒，但**攻击是 non-shifted 且有界**，单纯检测会丢掉太多任务。论文把防御写成在线 minimax 问题，并在可对角化假设下给出每个特征方向的最优正则化强度。结论是：鲁棒正则化不让攻击集中打最脆弱的单一方向，而是把风险分摊到一组 protected directions。

2 背景知识补充

2.1 连续学习与灾难性遗忘

连续学习的特点是数据不是一次性给出，而是按任务序列到达。第 t 个任务有数据集

$$D_t = \{(x_t^i, y_t^i)\}_{i=1}^{n_t}, \quad x_t^i \in \mathcal{X}, y_t^i \in \mathcal{Y}.$$

训练第 t 个任务时，通常不能再完整访问旧任务数据。因此模型既要学习新任务，又不能忘掉旧任务，这就是稳定性-可塑性权衡。

论文用全局超额风险衡量最终模型：

$$\mathcal{R}_T(w) = \sum_{t=1}^T \mathbb{E}_{z \sim \mathcal{D}_t} [\ell(w, z)] - \min_{w^*} \sum_{t=1}^T \mathbb{E}_{z \sim \mathcal{D}_t} [\ell(w^*, z)]. \quad (1)$$

它问的是：当前模型 w 和最优全局模型相比，多损失了多少。

2.2 正则化式 CL 更新

论文研究的核心算法族是

$$w_t \in \arg \min_{w'} \left\{ \frac{1}{n_t} \sum_{z \in D_t} \ell(w', z) + \frac{1}{2} \|w' - w_{t-1}\|_{H_t}^2 \right\}, \quad (2)$$

其中

$$\|u\|_{H_t}^2 = u^\top H_t u.$$

第一项要求模型适配当前任务；第二项惩罚离开上一轮模型 w_{t-1} 太远。矩阵 $H_t \succeq 0$ 决定哪些参数方向更应该被保护。

直觉上：

- $H_t = 0$ ：只管新任务，容易忘旧任务。
- H_t 很大：几乎冻结模型，旧知识保住了，但学不动新任务。
- H_t 是矩阵而不是标量：不同特征方向可以有不同保护强度。

2.3 数据投毒的三个维度

攻击者在任务 t 上加入扰动

$$\eta_t = (\eta_{x,t}, \eta_{y,t}), \quad \mathbb{E}[\|\eta_t\|_F^2] \leq M.$$

论文把扰动分解成

$$\eta_t = \hat{\eta}_t + \tilde{\eta}_t,$$

其中 $\hat{\eta}_t$ 是条件均值偏移， $\tilde{\eta}_t$ 是零均值随机扰动：

$$\mathbb{E}[\tilde{\eta}_t | \mathcal{I}_t] = 0.$$

三个攻击维度是：

维度	类型	含义
频率	frequent / infrequent	攻击任务数 $K = \Theta(T)$ 或 $K = O(1)$
强度	unbounded / bounded	单次预算 $M = \Omega(T)$ 或 $M = o(T)$
模式	shifted / non-shifted	是否有均值偏移 $\hat{\eta}_t \neq 0$

2.4 为什么会出现 Hessian、伪逆和混合二阶导

很多公式看起来复杂，是因为论文把“数据扰动如何影响参数更新”局部线性化。若

$$Q_t = \nabla_{ww}^2 \mathcal{L}(w_t^*, Z_t), \quad G_t = \nabla_{wZ}^2 \mathcal{L}(w_t^*, Z_t), \quad S_t = Q_t + H_t,$$

那么：

- Q_t 是当前任务损失对参数的曲率；

- G_t 衡量数据 Z_t 变化如何改变参数梯度;
- $S_t = Q_t + H_t$ 是“数据曲率 + 正则化曲率”;
- S_t^+ 是 Moore-Penrose 伪逆, 用来处理 S_t 不满秩的情况。

局部看, 投毒先通过 $G_t \eta_t$ 改变梯度, 再通过 S_t^+ 转化为参数偏移。所以敏感矩阵经常长成

$$S_t^+ G_t = (\nabla_{ww}^2 \mathcal{L}_t + H_t)^+ \nabla_{wZ}^2 \mathcal{L}_t.$$

2.5 线性回归设置

为了得到闭式证明, 论文后半部分使用多输出线性回归:

$$Y_t = X_t w^* + \varepsilon_t, \quad \mathbb{E}[\varepsilon_t^i | x_t^i] = 0, \quad \mathbb{E}[\varepsilon_t^i (\varepsilon_t^i)^\top | x_t^i] = \sigma^2 I. \quad (3)$$

平方损失是

$$\ell(w, (x, y)) = \frac{1}{2} \|x^\top w - y\|_2^2.$$

论文在这个设置下把参数矩阵向量化:

$$\mathbf{w}_t = \text{vec}(w_t), \quad \mathbf{X}_t = I_{p_2} \otimes X_t.$$

这里的 $\otimes$ 是 Kronecker 积。它的作用是把多输出线性回归写成普通向量形式:

$$\text{vec}(Y_t) = \mathbf{X}_t \text{vec}(w^*) + \text{vec}(\varepsilon_t).$$

3 命题 2.4 / 附录命题 A.1: 攻击目标的近似公式

3.1 结论形式

令

$$\mathcal{L}(w, Z_t) = \frac{1}{n_t} \sum_{z \in D_t} \ell(w, z), \quad w_t^* \in \arg \min_w \mathcal{L}(w, Z_t),$$

并记

$$P_t = \sum_{s=1}^t \nabla_{ww}^2 \mathcal{L}(w_s^*, Z_s).$$

对 non-shifted 攻击 $\tilde{\eta}_t$, 论文得到近似目标:

$$\begin{aligned} \max_{\tilde{\eta}_t} \quad & \frac{1}{2} \mathbb{E} \left[\|(\nabla_{ww}^2 \mathcal{L}_t + H_t)^+ \nabla_{wZ}^2 \mathcal{L}_t \text{vec}(\tilde{\eta}_t)\|_{P_t}^2 \right] + \text{高阶余项} \\ \text{s.t.} \quad & \mathbb{E}[\|\tilde{\eta}_t\|_F^2] \leq M. \end{aligned} \quad (4)$$

其中 $\mathcal{L}_t$ 是 $\mathcal{L}(w_t^*, Z_t)$ 的简写。

这条公式表达了一个核心事实: 攻击者会把预算放到

$$P_t^{1/2} (\nabla_{ww}^2 \mathcal{L}_t + H_t)^+ \nabla_{wZ}^2 \mathcal{L}_t$$

的最大奇异方向上, 因为这个方向让相同扰动造成最大的累计风险增量。

3.2 证明拆解

第一步：用经验风险替代真实风险。 真实风险 $\mathcal{R}_t(w_t)$ 依赖未知分布 $\mathcal{D}_1, \dots, \mathcal{D}_t$ 。CL 中旧数据也不可访问。因此论文先用已经出现任务的经验损失和来近似：

$$\sum_{\tau=1}^t \mathcal{L}(w_t, Z_\tau).$$

第二步：在每个任务最优点 w_τ^* 附近 Taylor 展开。 因为 w_τ^* 是任务 τ 的经验损失极小点，

$$\nabla_w \mathcal{L}(w_\tau^*, Z_\tau) = 0.$$

所以二阶展开给出

$$\sum_{\tau=1}^t \mathcal{L}(w_t, Z_\tau) = \sum_{\tau=1}^t \mathcal{L}(w_\tau^*, Z_\tau) + \frac{1}{2} \sum_{\tau=1}^t (w_t - w_\tau^*)^\top Q_\tau (w_t - w_\tau^*) + O\left(\sum_{\tau=1}^t \|w_t - w_\tau^*\|_2^3\right), \quad (5)$$

其中 $Q_\tau = \nabla_{ww}^2 \mathcal{L}(w_\tau^*, Z_\tau)$ 。

第三步：把投毒导致的更新写成局部线性方程。 带投毒数据 $Z_t + \eta_t$ 的一阶最优性条件是

$$\nabla_w \mathcal{L}(w_t, Z_t + \eta_t) + H_t(w_t - w_{t-1}) = 0.$$

在 (w_t^*, Z_t) 附近展开：

$$Q_t(w_t - w_t^*) + G_t \text{vec}(\eta_t) + H_t(w_t - w_{t-1}) + O(\|w_t - w_t^*\|_2^2 + \|\eta_t\|_F^2) = 0, \quad (6)$$

其中 $G_t = \nabla_{wZ}^2 \mathcal{L}(w_t^*, Z_t)$ 。整理得到，对任意旧任务 τ ，

$$w_t - w_\tau^* = S_t^+ [Q_t(w_t^* - w_\tau^*) + H_t(w_{t-1} - w_\tau^*) - G_t \text{vec}(\eta_t)] + O(\|w_t - w_t^*\|_2^2 + \|\eta_t\|_F^2), \quad (7)$$

其中 $S_t = Q_t + H_t$ 。

第四步：代回二次风险。 把 (7) 代入 (5)，所有和 η_t 无关的项对攻击者不重要，可以丢掉。留下的攻击相关部分是

$$\begin{aligned} & \frac{1}{2} \|S_t^+ G_t \text{vec}(\eta_t)\|_{P_t}^2 - \text{vec}(\eta_t)^\top G_t^\top S_t^+ \sum_{\tau=1}^t Q_\tau S_t^+ [Q_t(w_t^* - w_\tau^*) + H_t(w_{t-1} - w_\tau^*)] \\ & + O(\|\eta_t\|_F^2 + \|w_t - w_t^*\|_2^2) + O\left(\sum_{\tau=1}^t \|w_t - w_\tau^*\|_2^3\right). \end{aligned} \quad (8)$$

第五步：为什么 non-shifted 攻击没有线性项。 若

$$\eta_t = \hat{\eta}_t + \tilde{\eta}_t, \quad \mathbb{E}[\tilde{\eta}_t \mid Z_{1:t}, w_{t-1}] = 0,$$

那么 (8) 中关于 $\tilde{\eta}_t$ 的线性项取期望后为 0。因此 non-shifted 攻击的主导项只剩二次型，即 (4)。shifted 攻击 $\hat{\eta}_t$ 会保留线性项，所以它更危险：它能直接把模型均值推向错误方向。

4 定理 3.1: 为什么有些攻击根本防不住

4.1 定理含义

论文证明: 存在一些问题实例, 使得任意正则化式 CL 方法 (2) 都无法保证收敛。两类攻击是:

- frequent + shifted;
- frequent + unbounded + non-shifted。

证明只需要构造一维线性回归反例。

4.2 一维反例

设

$$p_1 = p_2 = n_t = 1, \quad x_t = 1, \quad y_t = w^* + \varepsilon_t,$$

平方损失 $\ell(w, z_t) = (w - y_t)^2$ 。正则化更新化为

$$w_t = \frac{1}{1 + H_t}(y_t + \eta_t) + \frac{H_t}{1 + H_t}w_{t-1}.$$

定义

$$c_t = \frac{H_t}{1 + H_t} \in [0, 1],$$

则

$$w_t - w^* = c_t(w_{t-1} - w^*) + (1 - c_t)(\varepsilon_t + \eta_t). \quad (9)$$

这个递推是整条证明的核心。

4.3 frequent shifted 攻击

令攻击每个任务, 并取常数偏移 $\eta_t = \Delta \neq 0$ 。设

$$m_t = \mathbb{E}[w_t - w^*],$$

由 (9) 得

$$m_t = c_t m_{t-1} + (1 - c_t)\Delta.$$

减去 Δ :

$$m_t - \Delta = c_t(m_{t-1} - \Delta),$$

所以

$$m_T = \Delta + \left(\prod_{t=1}^T c_t \right) (w_0 - w^* - \Delta).$$

现在分两种情况:

- 若 $\prod_{t=1}^T c_t \not\rightarrow 0$, 则即使无攻击无噪声, 初始偏差也不能被完全遗忘, 算法本来就不保证收敛。
- 若 $\prod_{t=1}^T c_t \rightarrow 0$, 则在 shifted 攻击下 $m_T \rightarrow \Delta$, 于是

$$\mathbb{E}[(w_T - w^*)^2] \geq (\mathbb{E}[w_T - w^*])^2 \rightarrow \Delta^2 > 0.$$

因此无论正则化策略如何选, 总有一种情形无法收敛。

4.4 frequent unbounded non-shifted 攻击

现在攻击仍然每个任务，但取零均值独立扰动：

$$\mathbb{E}[\tilde{\eta}_t] = 0, \quad \mathbb{E}[\tilde{\eta}_t^2] = M_T, \quad M_T = \Omega(T).$$

展开 (9)：

$$w_T - w^* = \left(\prod_{r=1}^T c_r \right) (w_0 - w^*) + \sum_{s=1}^T \beta_{s,T} (\varepsilon_s + \tilde{\eta}_s),$$

其中

$$\beta_{s,T} = (1 - c_s) \prod_{r=s+1}^T c_r.$$

这些权重满足望远镜恒等式

$$\sum_{s=1}^T \beta_{s,T} = 1 - \prod_{r=1}^T c_r.$$

如果 $\prod c_r \not\rightarrow 0$ ，初始偏差仍然不消失；否则

$$\sum_{s=1}^T \beta_{s,T} \rightarrow 1.$$

由 Cauchy 不等式

$$\sum_{s=1}^T \beta_{s,T}^2 \geq \frac{\left(\sum_{s=1}^T \beta_{s,T} \right)^2}{T} = \frac{(1 - \prod_{r=1}^T c_r)^2}{T}.$$

攻击方差给最终风险贡献至少

$$M_T \sum_{s=1}^T \beta_{s,T}^2 \geq M_T \frac{(1 - \prod_{r=1}^T c_r)^2}{T}.$$

因为 $M_T = \Omega(T)$ ，右端不会趋于 0。定理得证。

说明 4.1. 这个反例很重要。正则化 CL 必须靠 $c_t < 1$ 逐步忘掉初始偏差；但一旦每一步都混入有偏或巨大方差攻击，这种“持续吸收新数据”的机制本身就会把攻击吸收进去。

5 T2T 防御：少量但强攻击的检测与证明

5.1 检测分数的设计

少量但强攻击的关键困难是：攻击任务未知，而且 shifted 攻击可以非常大。最自然的防御是检测异常任务并回滚。但只看

$$\|w_t - w_{t-1}\|$$

会有归因问题：大更新可能来自当前任务被攻击，也可能来自当前良性任务在纠正过去被攻击造成的偏差。

T2T 使用两个连续更新：

$$w_t - w_{t-1}, \quad w_{t-1} - w_{t-2}.$$

检测分数为

$$d_t = \|D_t^1(w_t - w_{t-1}) - D_t^2(w_{t-1} - w_{t-2})\|. \quad (10)$$

其中

$$D_t^1 = (I - B_t)(A_t^+ - C_t A_t^\top), \quad (11)$$

$$D_t^2 = (I - B_t)(B_t^+ + C_t B_t^\top), \quad (12)$$

$$C_t = (A_t^+ A_t - B_t^+ B_t)(A_t^\top A_t + B_t^\top B_t)^+, \quad (13)$$

而

$$A_t = (\nabla_{ww}^2 \mathcal{L}_t + H_t)^{-1} \nabla_{ww}^2 \mathcal{L}_t (\nabla_{ww}^2 \mathcal{L}_{t-1} + H_{t-1})^{-1} H_{t-1}, \quad (14)$$

$$B_t = (\nabla_{ww}^2 \mathcal{L}_{t-1} + H_{t-1})^{-1} \nabla_{ww}^2 \mathcal{L}_{t-1}. \quad (15)$$

5.2 引理 4.1：为什么这个分数能隔离最近两个任务

引理说：

$$D_t^1(w_t - w_{t-1}) - D_t^2(w_{t-1} - w_{t-2}) = E_t^1(w_t^* - w_{t-1}^*) + E_t^2 \text{vec}(\eta_{t-1}) + E_t^3 \text{vec}(\eta_t) + \mathcal{E}_t, \quad (16)$$

其中

$$\mathcal{E}_t = O(\|w_t - w_t^*\|^2) + O(\|w_{t-1} - w_{t-1}^*\|^2) + O(\|\eta_t\|^2 + \|\eta_{t-1}\|^2).$$

最重要的是：右边没有 w_{t-2} 的历史项。

5.3 证明关键：构造 $D_t^1 A_t = D_t^2 B_t$

从线性化更新可得到

$$\begin{aligned} w_t - w_{t-1} &= -A_t(w_{t-2} - w_t^*) + S_t^+ Q_t S_{t-1}^+ Q_{t-1}(w_t^* - w_{t-1}^*) \\ &\quad + S_t^+ Q_t S_{t-1}^+ G_{t-1} \text{vec}(\eta_{t-1}) - S_t^+ G_t \text{vec}(\eta_t) + \text{高阶项}, \end{aligned} \quad (17)$$

$$w_{t-1} - w_{t-2} = -B_t(w_{t-2} - w_{t-1}^*) - S_{t-1}^+ G_{t-1} \text{vec}(\eta_{t-1}) + \text{高阶项}. \quad (18)$$

两式都含有历史状态 w_{t-2} 。为了消掉它，需要

$$D_t^1 A_t = D_t^2 B_t.$$

论文把 D_t^1, D_t^2 设计成下列最小二乘投影问题的解：

$$\min_{\bar{D}_t^1, \bar{D}_t^2} \|\bar{D}_t^1 - A_t^+\|_F^2 + \|\bar{D}_t^2 - B_t^+\|_F^2, \quad \text{s.t. } \bar{D}_t^1 A_t = \bar{D}_t^2 B_t.$$

解出来就是 (13) 中的形式，再乘上 $(I - B_t)$ 做归一化。代回 (17)-(18) 后，历史项抵消，只剩最近两个任务的任务差异和攻击项。

5.4 检测阈值: Lemma 4.3

在线性回归假设下，如果任务 $t-1$ 和 t 都是良性的，那么

$$d_t^2 = \|E_t^2 \mathbf{e}_{t-1} + E_t^3 \mathbf{e}_t\|_2^2.$$

噪声独立、零均值，且

$$\mathbb{E}[\mathbf{e}_s \mathbf{e}_s^\top | X_s] = \sigma^2 I.$$

因此交叉项期望为 0，

$$\mathbb{E}[d_t^2 | X_{t-1}, X_t] = \sigma^2 \text{tr}((E_t^2)^\top E_t^2) + \sigma^2 \text{tr}((E_t^3)^\top E_t^3). \quad (19)$$

用 Markov 不等式：

$$\Pr(d_t^2 > \theta_t^2) \leq \epsilon/T,$$

取

$$\theta_t = \sqrt{\frac{\sigma^2 T}{\epsilon} [\text{tr}((E_t^2)^\top E_t^2) + \text{tr}((E_t^3)^\top E_t^3)]}. \quad (20)$$

再对所有 t 用 union bound，得到同时成立概率至少 $1 - \epsilon$ 。

如果噪声是 sub-Gaussian，可以用 Hanson-Wright 不等式替代 Markov 不等式，阈值会从粗糙的 T/ϵ 型改善成对数型 $\log(T/\epsilon)$ 。

5.5 Theorem 4.4: 最终误差界

论文选用正则化矩阵

$$H_t = \frac{1}{n_t} \left(\frac{\sigma^2}{W} I + \sum_{s=1}^{t-1} \mathbf{X}_s^\top \mathbf{X}_s \right). \quad (21)$$

把攻击写成标签扰动 $\mathbf{n}_t$ ，其中未攻击时 $\mathbf{n}_t = 0$ 。线性回归递推为

$$\mathbf{w}_t - \mathbf{w}^* = \left(\frac{\mathbf{X}_t^\top \mathbf{X}_t}{n_t} + H_t \right)^{-1} \left[\frac{\mathbf{X}_t^\top (\mathbf{e}_t + \mathbf{n}_t)}{n_t} + H_t (\mathbf{w}_{t-1} - \mathbf{w}^*) \right]. \quad (22)$$

代入 (21) 并展开递推，有

$$\mathbf{w}_T - \mathbf{w}^* = \tilde{\mathbf{X}}_{T+1}^{-1} \left[\sum_{s=1}^T \mathbf{X}_s^\top (\mathbf{e}_s + \mathbf{n}_s) + \frac{\sigma^2}{W} (\mathbf{w}_0 - \mathbf{w}^*) \right], \quad (23)$$

其中

$$\tilde{\mathbf{X}}_{T+1} = \frac{\sigma^2}{W} I + \sum_{s=1}^T \mathbf{X}_s^\top \mathbf{X}_s.$$

把任务分成良性任务和漏检攻击任务 $\mathcal{K} = \{t_1, \dots, t_K\}$ 。检测到的攻击会被回滚丢弃，不进入最终递推；真正需要控制的是漏检攻击。由 T2T 阈值可推出，任何漏检攻击必须满足

$$\left\| \left(\frac{\mathbf{X}_t^\top \mathbf{X}_t}{n_t} \right)^+ \frac{\mathbf{X}_t^\top (\mathbf{n}_t + \mathbf{e}_t)}{n_t} \right\|_2^2 \leq \frac{\sigma^2 T}{\epsilon} \text{tr}((\mathbf{X}_t^\top \mathbf{X}_t)^+). \quad (24)$$

直观解释：如果攻击超过这个尺度，在某个最坏未来任务对齐下，下一次 T2T 分数会超过阈值，攻击会被检测并回滚。

由 (23),

$$\begin{aligned} \mathbb{E} \|\mathbf{w}_T - \mathbf{w}^*\|^2 &\leq \sigma^2 \text{tr}(\tilde{\mathbf{X}}_{T+1}^{-1}) \\ &\quad + K \sum_{k=1}^K \left\| \tilde{\mathbf{X}}_{T+1}^{-1} (\mathbf{X}_{t_k}^\top \mathbf{X}_{t_k}) \right\|_2^2 \frac{\sigma^2 T}{\epsilon} \text{tr}((\mathbf{X}_{t_k}^\top \mathbf{X}_{t_k})^+). \end{aligned} \quad (25)$$

第一项是良性噪声误差；第二项是漏检攻击误差。

若所有任务 **informative**，即每个参数方向都能在 T 个任务中得到线性数量的信息，则 $\tilde{\mathbf{X}}_{T+1}$ 的特征值按 $\Theta(T)$ 增长。于是

$$\text{tr}(\tilde{\mathbf{X}}_{T+1}^{-1}) = O(1/T), \quad \left\| \tilde{\mathbf{X}}_{T+1}^{-1} (\mathbf{X}_{t_k}^\top \mathbf{X}_{t_k}) \right\|_2^2 = O(1/T^2).$$

代入 (25) 得

$$\mathcal{R}(w_T) = O\left(\frac{K^2}{\epsilon T}\right).$$

当 $K = O(1)$ 时，最终误差收敛到 0。

6 频繁有界零均值攻击：鲁棒特征防御

6.1 为什么不能继续靠检测

如果几乎每个任务都被攻击，T2T 检测即使有效，也会不断丢任务，模型无法学习。此时要换思路：不再拒绝任务，而是调整正则化矩阵 H_t ，让模型对攻击最敏感的方向变得不敏感。

6.2 线性模型中的 minimax 递推

在向量化线性回归下，带 **non-shifted** 攻击的递推是

$$w_t - w_\star = S_t^{-1} \left[\frac{X_t^\top (\varepsilon_t + \tilde{\eta}_t)}{n_t} + H_t(w_{t-1} - w_\star) \right], \quad S_t = \frac{X_t^\top X_t}{n_t} + H_t. \quad (26)$$

因为 $\tilde{\eta}_t$ 是零均值并与历史误差条件不相关，

$$\mathbb{E}[w_t - w_\star] = S_t^{-1} H_t \mathbb{E}[w_{t-1} - w_\star], \quad (27)$$

$$\begin{aligned} \text{Cov}(w_t - w_\star) &= S_t^{-1} \frac{X_t^\top}{n_t} (\text{Cov}(\tilde{\eta}_t) + \sigma^2 I) \frac{X_t}{n_t} S_t^{-1} \\ &\quad + S_t^{-1} H_t \text{Cov}(w_{t-1} - w_\star) H_t^\top S_t^{-1}. \end{aligned} \quad (28)$$

于是防御者在每轮求解

$$\begin{aligned} \min_{H_t} \max_{\text{Cov}(\tilde{\eta}_t) \succeq 0} & \left\| S_t^{-1} H_t \mathbb{E}[w_{t-1} - w_\star] \right\|_2^2 \\ & + \text{tr} \left(S_t^{-1} \frac{X_t^\top}{n_t} (\text{Cov}(\tilde{\eta}_t) + \sigma^2 I) \frac{X_t}{n_t} S_t^{-1} \right) \\ & + \text{tr} \left(S_t^{-1} H_t \text{Cov}(w_{t-1} - w_\star) H_t^\top S_t^{-1} \right) \\ \text{s.t. } & \text{tr}(\text{Cov}(\tilde{\eta}_t)) \leq M. \end{aligned} \quad (29)$$

6.3 对角化假设与每个方向的风险

假设所有任务 Hessian 两两可交换：

$$X_s^\top X_s X_t^\top X_t = X_t^\top X_t X_s^\top X_s.$$

则它们可以被同一个正交矩阵 $U = [u_1, \dots, u_p]$ 同时对角化：

$$\frac{X_t^\top X_t}{n_t} = U \Gamma_t U^\top, \quad \Gamma_t = \text{diag}(\gamma_1^t, \dots, \gamma_p^t).$$

只需考虑

$$H_t = U \Lambda_t U^\top, \quad \Lambda_t = \text{diag}(\lambda_1^t, \dots, \lambda_p^t).$$

定义第 j 个方向的误差贡献

$$\mathcal{R}_j^t = \mathbb{E}[(u_j^\top (w_t - w_\star))^2], \quad \mathcal{R}(w_t) = \sum_{j=1}^p \mathcal{R}_j^t.$$

投影到 u_j 方向，若 $\gamma_j^t > 0$ ，有

$$u_j^\top (w_t - w_\star) = \frac{1}{\lambda_j^t + \gamma_j^t} \left[\frac{\sqrt{\gamma_j^t}}{\sqrt{n_t}} (v_j^t)^\top (\varepsilon_t + \tilde{\eta}_t) + \lambda_j^t u_j^\top (w_{t-1} - w_\star) \right], \quad (30)$$

其中 $v_j^t = X_t u_j / \sqrt{n_t \gamma_j^t}$ 且 $\|v_j^t\| = 1$ 。由零均值和不相关性，

$$\mathcal{R}_j^t = \left(\frac{\lambda_j^t}{\lambda_j^t + \gamma_j^t} \right)^2 \mathcal{R}_j^{t-1} + \frac{\gamma_j^t (\sigma^2 + (v_j^t)^\top \text{Cov}(\tilde{\eta}_t) v_j^t)}{n_t (\lambda_j^t + \gamma_j^t)^2}. \quad (31)$$

固定 λ_j^t 后，攻击者的目标对 $\text{Cov}(\tilde{\eta}_t)$ 是线性的。所以最优攻击把全部预算 M 放到最敏感方向：

$$j^\star \in \arg \max_j \frac{\gamma_j^t}{n_t (\lambda_j^t + \gamma_j^t)^2}, \quad \text{Cov}(\tilde{\eta}_t) = M v_{j^\star}^t (v_{j^\star}^t)^\top.$$

于是防御问题等价于

$$\min_{\lambda_1^t, \dots, \lambda_p^t} \max_j \frac{M \gamma_j^t}{n_t (\lambda_j^t + \gamma_j^t)^2} + \sum_{j=1}^p \left[\left(\frac{\lambda_j^t}{\lambda_j^t + \gamma_j^t} \right)^2 \mathcal{R}_j^{t-1} + \frac{\gamma_j^t \sigma^2}{n_t (\lambda_j^t + \gamma_j^t)^2} \right]. \quad (32)$$

6.4 Proposition 5.2：最优正则化的水位结构

令

$$\tilde{\gamma}_j^t = \gamma_j^t n_t, \quad \mathcal{I}_t^+ = \{j : \tilde{\gamma}_j^t > 0, \mathcal{R}_j^{t-1} > 0\}.$$

对 $j \in \mathcal{I}_t^+$ ，定义

$$b_j^t = \frac{\mathcal{R}_j^{t-1} \tilde{\gamma}_j^t + \sigma^2}{\mathcal{R}_j^{t-1} \sqrt{\tilde{\gamma}_j^t}}.$$

按 b_j^t 从小到大排序。再定义

$$A_j^t = \frac{M + j \sigma^2 + \sum_{k=1}^j \mathcal{R}_k^{t-1} \tilde{\gamma}_k^t}{\sum_{k=1}^j \mathcal{R}_k^{t-1} \sqrt{\tilde{\gamma}_k^t}}.$$

令 j_t 是满足

$$A_j^t > b_j^t$$

的最大 j 。那么最优防御为

$$\lambda_j^t = \begin{cases} \frac{\sigma^2}{n_t \mathcal{R}_j^{t-1}}, & j \in \mathcal{I}_t^+, j > j_t, \\ A_{j_t}^t \sqrt{\frac{\gamma_j^t}{n_t}} - \gamma_j^t, & j \in \mathcal{I}_t^+, j \leq j_t, \\ +\infty, & \gamma_j^t > 0, \mathcal{R}_j^{t-1} = 0, \\ \text{任意正数}, & \gamma_j^t = 0. \end{cases} \quad (33)$$

6.5 Proposition 5.2 的证明

证明从变量替换开始：

$$c_j^t = \frac{\lambda_j^t}{\lambda_j^t + \gamma_j^t}.$$

这表示第 j 个方向保留旧模型的比例； $1 - c_j^t$ 表示当前任务数据进入模型的比例。

忽略退化方向后，问题变成

$$\begin{aligned} \min_{\{c_j^t\}, z} \quad & \sum_{j \in \mathcal{I}_t^+} \left[(c_j^t)^2 \mathcal{R}_j^{t-1} + \frac{(1 - c_j^t)^2 \sigma^2}{n_t \gamma_j^t} \right] + zM \\ \text{s.t. } \quad & z \geq \frac{(1 - c_j^t)^2}{\gamma_j^t n_t}, \quad j \in \mathcal{I}_t^+. \end{aligned} \quad (34)$$

这里 z 代表最大攻击敏感度。

对约束引入乘子 $\chi_j \geq 0$ 。KKT 条件给出

$$\sum_{j \in \mathcal{I}_t^+} \chi_j = M$$

以及

$$c_j^t = \frac{(\sigma^2 + \chi_j)/(n_t \gamma_j^t)}{\mathcal{R}_j^{t-1} + (\sigma^2 + \chi_j)/(n_t \gamma_j^t)}. \quad (35)$$

若 $\chi_j > 0$ ，说明方向 j 的最大敏感度约束是活跃的：

$$z = \frac{(1 - c_j^t)^2}{\gamma_j^t n_t}.$$

把 (35) 代入可得

$$\chi_j = \frac{\mathcal{R}_j^{t-1} \sqrt{\gamma_j^t n_t}}{\sqrt{z}} - \sigma^2 - \gamma_j^t n_t \mathcal{R}_j^{t-1}. \quad (36)$$

设活跃集合为 $J_t = \{j : \chi_j > 0\}$ 。由 $\sum \chi_j = M$ 得

$$\frac{1}{\sqrt{z}} = \frac{M + |J_t| \sigma^2 + \sum_{j \in J_t} \gamma_j^t n_t \mathcal{R}_j^{t-1}}{\sum_{j \in J_t} \mathcal{R}_j^{t-1} \sqrt{\gamma_j^t n_t}}.$$

这就是 A_j^t 的来源。

接下来要确定 J_t 。令

$$a_j = \mathcal{R}_j^{t-1} \sqrt{\gamma_j^t n_t}, \quad b_j = \frac{\gamma_j^t n_t \mathcal{R}_j^{t-1} + \sigma^2}{\mathcal{R}_j^{t-1} \sqrt{\gamma_j^t n_t}}.$$

对任意候选活跃集合 J ，KKT 条件给出

$$\chi_k = a_k(A_J - b_k).$$

因此：

$$k \in J \Rightarrow b_k < A_J, \quad k \notin J \Rightarrow b_k \geq A_J.$$

所以活跃集合必须是按 b_j 排序后的一个前缀。最大满足 $A_j^t > b_j^t$ 的 j 就是前缀长度 j_t 。

最后由

$$\lambda_j^t = \frac{c_j^t \gamma_j^t}{1 - c_j^t}$$

还原回 λ_j^t ，得到 (33)。

说明 6.1. b_j^t 越小，方向 j 越容易进入 **protected set**。直观上，这些方向要么当前特征信息弱，要么历史误差大，要么噪声相对影响强，因此更容易被攻击者利用。

6.6 Theorem 5.3：为什么鲁棒特征防御更快

定理考虑一个特殊平稳情形：**protected set** 长期固定为

$$\{1, \dots, j_T\}.$$

对 **protected directions** 定义总误差

$$\Phi_t = \sum_{j=1}^{j_T} \mathcal{R}_j^t, \quad f_j^t = \frac{\mathcal{R}_j^t}{\Phi_t}.$$

假设 $f_j^t \rightarrow f_j$ ，且 $\tilde{\gamma}_j^t \rightarrow \tilde{\gamma}_j^T$ 。

在 **protected directions** 上，KKT 条件让攻击敏感度相等：

$$\frac{(1 - c_j^t)^2}{\tilde{\gamma}_j^t} = z_t, \quad j = 1, \dots, j_T.$$

因此

$$c_j^t = 1 - \sqrt{z_t \tilde{\gamma}_j^t}.$$

由 KKT 水位公式：

$$\sqrt{z_t} = \frac{\sum_{i=1}^{j_T} \sqrt{\tilde{\gamma}_i^t} \mathcal{R}_i^{t-1}}{M + j_T \sigma^2 + \sum_{i=1}^{j_T} \tilde{\gamma}_i^t \mathcal{R}_i^{t-1}}.$$

把 **protected directions** 的风险加总，得到核心递推：

$$\Phi_t = \Phi_{t-1} - \frac{\left(\sum_{j=1}^{j_T} \sqrt{\tilde{\gamma}_j^t} \mathcal{R}_j^{t-1} \right)^2}{M + j_T \sigma^2 + \sum_{j=1}^{j_T} \tilde{\gamma}_j^t \mathcal{R}_j^{t-1}}. \quad (37)$$

把 $\mathcal{R}_j^{t-1} = f_j^{t-1} \Phi_{t-1}$ 代入，并取倒数，可写成

$$\frac{1}{\Phi_t} - \frac{1}{\Phi_{t-1}} = \frac{\left(\sum_{j=1}^{j_T} f_j^{t-1} \sqrt{\tilde{\gamma}_j^t}\right)^2}{M + j_T \sigma^2 + \Phi_{t-1} \left[\sum_{j=1}^{j_T} f_j^{t-1} \tilde{\gamma}_j^t - \left(\sum_{j=1}^{j_T} f_j^{t-1} \sqrt{\tilde{\gamma}_j^t}\right)^2\right]}. \quad (38)$$

Cauchy 不等式保证中括号非负，因此 Φ_t 单调下降。在平稳假设下，分子收敛到

$$C_\star = \left(\sum_{j=1}^{j_T} f_j \sqrt{\tilde{\gamma}_j^T}\right)^2 > 0,$$

而 $\Phi_t \rightarrow 0$ ，所以分母最终趋于 $M + j_T \sigma^2$ 。于是

$$\frac{1}{\Phi_t} - \frac{1}{\Phi_{t-1}} \rightarrow \frac{C_\star}{M + j_T \sigma^2}.$$

累加并用 Cesaro 平均得到

$$\Phi_T \sim \frac{M + j_T \sigma^2}{T \left(\sum_{j=1}^{j_T} f_j \sqrt{\tilde{\gamma}_j^T}\right)^2}.$$

对非 protected directions，攻击者不投预算，递推退化为

$$\mathcal{R}_j^t = \frac{\sigma^2 \mathcal{R}_j^{t-1}}{\sigma^2 + \tilde{\gamma}_j^t \mathcal{R}_j^{t-1}}.$$

取倒数：

$$\frac{1}{\mathcal{R}_j^t} = \frac{1}{\mathcal{R}_j^{t-1}} + \frac{\tilde{\gamma}_j^t}{\sigma^2}.$$

展开得

$$\mathcal{R}_j^T \leq \frac{\sigma^2}{\sigma^2/W + \sum_{t=1}^T \tilde{\gamma}_j^t}.$$

因此鲁棒防御的总误差为

$$\mathcal{R}(w_T) \lesssim \frac{M + j_T \sigma^2}{T \left(\sum_{j=1}^{j_T} f_j \sqrt{\tilde{\gamma}_j^T}\right)^2} + \sum_{j=j_T+1}^p \frac{\sigma^2}{\sigma^2/W + \sum_{\tau=1}^T \tilde{\gamma}_j^\tau}. \quad (39)$$

6.7 和普通正则化 / EWC 型基线的比较

基线使用

$$H_t = \frac{1}{n_t} \left(\frac{\sigma^2}{W} I + \sum_{\tau=1}^{t-1} X_\tau^\top X_\tau \right).$$

在方向 j 上，最终噪声权重约为

$$\frac{\sqrt{\tilde{\gamma}_j^t}}{\sigma^2/W + \sum_{\tau=1}^T \tilde{\gamma}_j^\tau}.$$

攻击者每轮把预算投到最坏方向，攻击项变成

$$M \max_j \frac{\sum_{t=1}^T \tilde{\gamma}_j^t}{\left(\sigma^2/W + \sum_{t=1}^T \tilde{\gamma}_j^t\right)^2}.$$

平稳时

$$\sum_{t=1}^T \tilde{\gamma}_j^t \sim T \tilde{\gamma}_j^T,$$

于是基线攻击项近似

$$\max_j \frac{M}{T \tilde{\gamma}_j^T}.$$

这意味着一个小 $\tilde{\gamma}_j^T$ 的脆弱方向就可能主导误差。鲁棒特征防御则用 **protected set** 把敏感度平均化，攻击项变为

$$\frac{M + j_T \sigma^2}{T \left(\sum_{j=1}^{j_T} f_j \sqrt{\tilde{\gamma}_j^T} \right)^2},$$

不再完全由单个最坏方向决定。

7 实验部分怎么读

实验不是证明的核心，但它验证了两个理论直觉。

- 对 **infrequent shifted attacks**, T2T 检测分数 d_t 在攻击任务附近出现峰值。即使测试准确率看起来没明显变化，微观更新分数仍能暴露攻击。
- 对 **frequent bounded non-shifted attacks**, iCaRL 这类 **replay/memorization** 方法在频繁攻击下可能更脆弱，因为它没有显式正则化矩阵来降低敏感方向。鲁棒特征防御比普通 EWC 型正则化收敛更快。

8 读公式的路线图

如果从头读论文很吃力，可以按以下顺序理解。

1. 先看 (2)。所有防御都只是在设计 H_t 或通过检测让 $H_t \rightarrow \infty$ 。
2. 再看 (4)。它告诉你攻击者为什么打最大奇异方向。
3. 用一维递推 (9) 理解 Theorem 3.1。这个定理不需要复杂矩阵。
4. 用等式 $D_t^1 A_t = D_t^2 B_t$ 理解 T2T。它解释了为什么 d_t 能消去历史。
5. 用 (23) 理解 T2T 的收敛界。最终模型就是所有噪声与攻击的加权和。
6. 用 (31) 理解鲁棒特征防御。每个特征方向有一个独立风险递推。
7. 用 KKT 条件理解 (33)。**protected set** 是一个排序后的前缀集合。
8. 最后看 (38)。Theorem 5.3 的 $O(1/T)$ 来自倒数递推。

9 这篇论文的假设与局限

- 最完整的证明建立在线性回归和平方损失上。论文用 NTK 和预训练线性头解释为什么这对非线性模型有启发，但严格结论仍然依赖线性化结构。

- T2T 防御需要维护最近几个模型、正则化矩阵和 Hessian 信息。高维神经网络中必须用 Hessian 近似。
- Theorem 4.4 中 informative tasks 假设很关键。若某些参数方向长期没有数据信息，即使没有攻击也不能保证收敛。
- Theorem 5.3 的闭式收敛率依赖 protected set 平稳、Hessian 可同时对角化等假设。这些假设主要用于给出可解释的理论形式。
- 攻击预算 M 在鲁棒特征防御中需要被知道或至少有上界。若上界过松，正则化可能过保守。

10 一句话总结

这篇论文的核心观点是：连续学习中的投毒攻击不是普通噪声，而是沿时间累积的策略性偏置。频繁均值偏移或巨大方差攻击会打破任何正则化 CL 的收敛保证；少量强攻击可以通过 task-to-task 投影检测并回滚；频繁有界零均值攻击则需要在 Hessian 特征方向上做 minimax 正则化，把攻击者最想利用的敏感方向压平。

参考文献

- [1] Yiting Hu and Lingjie Duan. *Theory of Continual Learning Against Data Poisoning Attacks*. arXiv:2606.29841, 2026.