

论文公式与证明导读

Theory of Continual Learning Against Data Poisoning Attacks

阅读笔记与证明讲解

2026 年 7 月 9 日

目录

1 先给结论：这篇论文到底在证明什么	4
2 背景知识补充	4
2.1 连续学习与灾难性遗忘	4
2.2 第一个风险公式逐符号解释	5
2.3 经验损失、 Z_t 、 $\mathcal{L}(w_t, Z_\tau)$	5
2.4 正则化式 CL 更新	6
2.5 范数符号：两个竖线和下标是什么意思	7
2.6 数据投毒的三个维度	7
2.7 在线 minimax 问题是什么	8
2.8 Taylor 展开、一阶最优性和曲率	8
2.9 为什么会出现 Hessian、伪逆和混合二阶导	9
2.10 Moore-Penrose 伪逆是什么	10
2.11 Kronecker 积、 I_{p_2} 和最大奇异方向	10
2.12 线性回归设置	11
3 进一步答疑：把概念和例子补齐	11
3.1 顺序到来的任务里，怎么谈全局最优	11
3.2 为什么最优解可能不唯一，最小范数是什么意思	12
3.3 论文到底用不用平方损失	12
3.4 H_t 的维度怎么确定	13
3.5 全局超额风险和正则化更新公式的关系	13
3.6 label poisoning 是训练阶段攻击吗	13
3.7 零均值扰动是否代表分布不变	14
3.8 攻击者知道什么	14
3.9 这些矩阵都是 Hessian 吗	14
3.10 KKT 条件是什么	14
3.11 为什么向量 Taylor 展开要有转置	15
3.12 一阶最优性等式不能随便写	15

3.13 G_t 的作用用一个线性回归例子看	16
3.14 奇异、不满秩会造成什么影响	16
3.15 为什么把 w 拉直成 $\text{vec}(w)$	17
3.16 为什么要做奇异值分解	17
3.17 噪声协方差公式是什么意思	18
3.18 为什么写 P_t	18
3.19 从正则化目标到论文式 (4) 的思路	18
3.20 攻击预算为什么用 Frobenius 范数	19
3.21 攻击预算为什么会放到最大奇异方向	19
4 命题 2.4 / 附录命题 A.1: 攻击目标的近似公式	19
4.1 结论形式	19
4.2 证明拆解	20
5 定理 3.1: 为什么有些攻击根本防不住	22
5.1 定理含义	22
5.2 一维反例	23
5.3 frequent shifted 攻击	24
5.4 frequent unbounded non-shifted 攻击	24
6 T2T 防御: 少量但强攻击的检测与证明	26
6.1 先不看公式: T2T 到底想做什么	26
6.2 检测分数的设计	27
6.3 引理 4.1: 为什么这个分数能隔离最近两个任务	28
6.4 证明关键: 构造 $D_t^1 A_t = D_t^2 B_t$	28
6.5 把 T2T 公式 10-25 连成一条推导链	28
6.6 检测阈值: Lemma 4.3	34
6.7 Theorem 4.4: 最终误差界	34
7 频繁有界零均值攻击: 鲁棒特征防御	35
7.1 先不看公式: 第二种防御的整体逻辑	35
7.2 为什么不能继续靠检测	36
7.3 线性模型中的 minimax 递推	36
7.4 对角化假设与每个方向的风险	37
7.5 Proposition 5.2: 最优正则化的水位结构	38
7.6 Proposition 5.2 的证明	38
7.7 Theorem 5.3: 为什么鲁棒特征防御更快	39
7.8 和普通正则化 / EWC 型基线的比较	41
8 实验部分怎么读	41
9 读公式的路线图	41

目录	3
10 这篇论文的假设与局限	42
11 一句话总结	42

1 先给结论：这篇论文到底在证明什么

这篇论文研究的是：在连续学习（continual learning, CL）中，模型按任务序列 $1, 2, \dots, T$ 依次训练。如果攻击者在部分任务的数据里加入投毒扰动，正则化式连续学习方法什么时候一定防不住，什么时候可以设计出有证明保证的防御。

论文的三条主线如下。

1. **不可防御边界**。如果攻击很频繁，并且攻击能改变数据均值（shifted attack），或者虽然不改变均值但每次攻击方差预算随 T 线性增长，那么任何形如

$$w_t \in \arg \min_w \left\{ \frac{1}{n_t} \sum_{z \in D_t} \ell(w, z) + \frac{1}{2} \|w - w_{t-1}\|_{H_t}^2 \right\}$$

的正则化式 CL 方法都无法保证最终误差收敛到 0。

2. **少量但可能无限强的攻击可以用检测加回滚防御**。对于只攻击有限多个任务但单次攻击强度可以很大的情形，论文设计了 task-to-task verification (T2T) 检测分数 d_t 。它通过两个相邻更新 $w_t - w_{t-1}$ 与 $w_{t-1} - w_{t-2}$ 的投影组合，消去历史状态 w_{t-2} 的影响。最终证明：只要攻击任务数 K 不随 T 线性增长，最终误差可达到

$$\mathcal{R}(w_T) = O\left(\frac{K^2}{\epsilon T}\right)$$

量级。

3. **频繁但有界、零均值攻击需要鲁棒特征正则化**。如果几乎每个任务都可能被投毒，但攻击是 non-shifted 且有界，单纯检测会丢掉太多任务。论文把防御写成在线 minimax 问题，并在可对角化假设下给出每个特征方向的最优正则化强度。结论是：鲁棒正则化不让攻击集中打最脆弱的单一方向，而是把风险分摊到一组 protected directions。

2 背景知识补充

2.1 连续学习与灾难性遗忘

连续学习的特点是数据不是一次性给出，而是按任务序列到达。第 t 个任务有数据集

$$D_t = \{(x_t^i, y_t^i)\}_{i=1}^{n_t}, \quad x_t^i \in \mathcal{X}, y_t^i \in \mathcal{Y}.$$

训练第 t 个任务时，通常不能再完整访问旧任务数据。因此模型既要学习新任务，又不能忘掉旧任务，这就是稳定性-可塑性权衡。

论文用全局超额风险衡量最终模型：

$$\mathcal{R}_T(w) = \sum_{t=1}^T \mathbb{E}_{z \sim \mathcal{D}_t} [\ell(w, z)] - \min_{w^*} \sum_{t=1}^T \mathbb{E}_{z \sim \mathcal{D}_t} [\ell(w^*, z)]. \quad (1)$$

它问的是：当前模型 w 和最优全局模型相比，多损失了多少。

2.2 第一个风险公式逐符号解释

公式 (1) 是论文最早出现、也最容易让人迷路的公式。把它拆开看：

$$\mathcal{R}_T(w) = \underbrace{\sum_{t=1}^T \mathbb{E}_{z \sim \mathcal{D}_t} [\ell(w, z)]}_{\text{当前模型 } w \text{ 在所有任务上的总期望损失}} - \underbrace{\min_u \sum_{t=1}^T \mathbb{E}_{z \sim \mathcal{D}_t} [\ell(u, z)]}_{\text{所有模型里能达到的最小总期望损失}}.$$

这里每个符号的含义是：

- T ：总任务数。
- t ：任务下标， $t = 1, \dots, T$ 。
- $\mathcal{D}_t$ ：第 t 个任务背后的真实数据分布。它不是数据集本身，而是产生数据的概率规律。
- z ：一个样本的简写。全文默认 $z = (x, y)$ ，其中 x 是输入特征， y 是标签或响应。
- $z \sim \mathcal{D}_t$ ：从第 t 个任务的数据分布中随机抽一个样本。
- $\ell(w, z)$ ：模型参数为 w 时，在样本 $z = (x, y)$ 上的损失。例如平方损失是

$$\ell(w, (x, y)) = \frac{1}{2} \|x^\top w - y\|_2^2.$$

- $\mathbb{E}_{z \sim \mathcal{D}_t} [\ell(w, z)]$ ：模型 w 在第 t 个任务上的平均损失。注意这是对真实分布求平均，不只是对训练集求平均。
- $\sum_{t=1}^T$ ：把所有任务的损失加起来。
- $\min_u$ ：在所有可能参数 u 里找总损失最小的那个值。这里用 u 是为了避免和真正选出的最优模型混淆。

所谓**最优全局模型**就是

$$w_{\text{glob}}^* \in \arg \min_u \sum_{t=1}^T \mathbb{E}_{z \sim \mathcal{D}_t} [\ell(u, z)].$$

它是“如果你事先知道所有任务的真实分布，并且可以一次性训练，那么最好的参数”。CL 算法实际只能顺序看到任务，所以 w_T 通常达不到 w_{glob}^* 。超额风险 $\mathcal{R}_T(w_T)$ 就是在衡量差距。

如果最优解不唯一，理论里常见做法是任选一个最优解，或者在所有最优解里选范数最小的那个。论文后面的线性回归设置通常直接假设存在共享真实参数 w^* ，这时 w^* 就扮演全局目标模型。

2.3 经验损失、 Z_t 、 $\mathcal{L}(w_t, Z_t)$

真实期望 $\mathbb{E}_{z \sim \mathcal{D}_t}$ 通常算不出来，因为我们不知道 $\mathcal{D}_t$ 。训练时能用的是数据集

$$D_t = \{z_t^1, \dots, z_t^{n_t}\}, \quad z_t^i = (x_t^i, y_t^i).$$

论文有时用 Z_t 表示“把任务 t 的全部样本拼起来形成的数据矩阵/数据集”。你可以先把 Z_t 理解成 D_t 的矩阵版。

任务 t 的**经验损失**定义为

$$\mathcal{L}(w, Z_t) = \frac{1}{n_t} \sum_{i=1}^{n_t} \ell(w, z_t^i).$$

所以

$$\mathcal{L}(w_t, Z_\tau) = \frac{1}{n_\tau} \sum_{i=1}^{n_\tau} \ell(w_t, z_\tau^i)$$

的意思是：把“第 t 步得到的模型 w_t ”拿去评估“第 τ 个任务的数据 Z_τ ”上的平均损失。

论文中出现的经验损失和

$$\sum_{\tau=1}^t \mathcal{L}(w_t, Z_\tau)$$

就是

$$\mathcal{L}(w_t, Z_1) + \mathcal{L}(w_t, Z_2) + \cdots + \mathcal{L}(w_t, Z_t),$$

意思是：当前模型 w_t 在已经见过的所有任务训练集上的总经验损失。它是下面这个真实全局风险的可计算替代物：

$$\sum_{\tau=1}^t \mathbb{E}_{z \sim \mathcal{D}_\tau} [\ell(w_t, z)].$$

2.4 正则化式 CL 更新

论文研究的核心算法族是

$$w_t \in \arg \min_{w'} \left\{ \frac{1}{n_t} \sum_{z \in D_t} \ell(w', z) + \frac{1}{2} \|w' - w_{t-1}\|_{H_t}^2 \right\}, \quad (2)$$

其中

$$\|u\|_{H_t}^2 = u^\top H_t u.$$

第一项要求模型适配当前任务；第二项惩罚离开上一轮模型 w_{t-1} 太远。矩阵 $H_t \succeq 0$ 决定哪些参数方向更该被保护。

为什么“适配当前任务”对应第一项？如果完全不考虑旧任务，第 t 步最自然的训练目标就是最小化当前任务训练集上的平均损失：

$$\min_{w'} \frac{1}{n_t} \sum_{z \in D_t} \ell(w', z).$$

这就是普通监督学习的经验风险最小化。CL 的问题是不能只管当前任务，否则会忘掉过去。因此论文在这个目标后面加上

$$\frac{1}{2} \|w' - w_{t-1}\|_{H_t}^2,$$

要求新参数 w' 不要离上一轮参数 w_{t-1} 太远。

为什么要引入 H_t ？如果只用一个标量 $\lambda \|w' - w_{t-1}\|_2^2$ ，所有参数方向被同等保护。但真实模型里有些方向对旧任务很重要，有些方向不重要。矩阵 H_t 可以给不同方向不同惩罚强度。若 H_t 在某一个方向上特征值大，模型就很难沿那个方向移动；若特征值小，模型可以更自由地更新。

直觉上：

- $H_t = 0$ ：只管新任务，容易忘旧任务。
- H_t 很大：几乎冻结模型，旧知识保住了，但学不动新任务。
- H_t 是矩阵而不是标量：不同特征方向可以有不同保护强度。

2.5 范数符号：两个竖线和下标是什么意思

论文里大量出现 $\|\cdot\|$ 、 $\|\cdot\|_2$ 、 $\|\cdot\|_F$ 、 $\|\cdot\|_H$ 。它们都表示“大小”，但对象不同。

- 向量二范数：

$$\|v\|_2 = \sqrt{v_1^2 + \cdots + v_d^2}.$$

下标 2 表示平方和再开方。没有下标时，很多论文默认也是二范数。

- 矩阵 Frobenius 范数：

$$\|A\|_F = \sqrt{\sum_{i,j} A_{ij}^2}.$$

它就是把矩阵所有元素平方求和再开方。

- 矩阵谱范数：

$$\|A\|_2 = \max_{\|x\|_2=1} \|Ax\|_2.$$

它表示矩阵最多能把一个单位向量放大多少倍，也等于最大奇异值。

- 加权范数：

$$\|u\|_H^2 = u^\top H u.$$

若 $H = I$ ，它就是普通二范数平方；若 $H \neq I$ ，不同方向被赋予不同权重。

2.6 数据投毒的三个维度

攻击者在任务 t 上加入扰动

$$\eta_t = (\eta_{x,t}, \eta_{y,t}), \quad \mathbb{E}[\|\eta_t\|_F^2] \leq M.$$

论文把扰动分解成

$$\eta_t = \hat{\eta}_t + \tilde{\eta}_t,$$

其中 $\hat{\eta}_t$ 是条件均值偏移， $\tilde{\eta}_t$ 是零均值随机扰动：

$$\mathbb{E}[\tilde{\eta}_t \mid \mathcal{I}_t] = 0.$$

为什么扰动既写在 x 又写在 y ？因为训练数据样本是 (x, y) 。现实攻击可以改输入，例如图像里加触发器、传感器特征被污染；也可以改标签，例如把类别标错或在线性回归中改变响应值。论文先给出最一般的投毒形式

$$(x_t^i, y_t^i) \mapsto (x_t^i + \eta_{x,t}^i, y_t^i + \eta_{y,t}^i),$$

后面为了可证明性，在线性回归理论分析中主要研究 **label poisoning**，也就是只改 y ，不改 x 。

零均值随机扰动

$$\mathbb{E}[\tilde{\eta}_t \mid \mathcal{I}_t] = 0$$

的意思是：在攻击者已经知道历史、当前模型、当前数据等信息 $\mathcal{I}_t$ 之后， $\tilde{\eta}_t$ 的条件平均仍然是 0。它不持续把数据往某个固定方向推偏，但可以增加方差。举例： $\tilde{\eta}_t$ 以一半概率取 $+a$ ，一半概率取 $-a$ ，平均就是 0。

三个攻击维度是：

维度	类型	含义
频率	frequent / infrequent	攻击任务数 $K = \Theta(T)$ 或 $K = O(1)$
强度	unbounded / bounded	单次预算 $M = \Omega(T)$ 或 $M = o(T)$
模式	shifted / non-shifted	是否有均值偏移 $\hat{\eta}_t \neq 0$

2.7 在线 minimax 问题是什么

minimax 的字面意思是“我先选策略，使得对手在最坏情况下造成的损失最小”。形式上常写成

$$\min_{\text{防御策略}} \max_{\text{攻击策略}} \text{损失}.$$

在这篇论文里，每个时刻 t 都有一次对抗：

$$\min_{H_t} \max_{\eta_t} \mathcal{R}_t(w_t),$$

防御者选正则化矩阵 H_t ，攻击者选投毒扰动 η_t ，双方围绕最终风险对抗。

为什么叫**在线**？因为任务按时间到达。第 t 轮只能用当前和历史信息，不能提前知道未来任务。在线 minimax 通常有几类解决方法：

- 直接求 saddle point，即找一组策略让双方都无法单方面改进。
- 把内层最大化先解掉，变成一个单独的最小化问题。
- 用凸优化和 KKT 条件求闭式解。
- 在矩阵问题太复杂时，通过对角化把矩阵问题拆成多个一维标量问题。

这篇论文为什么需要对角化？因为 H_t 、 $X_t^\top X_t$ 、协方差矩阵都是高维矩阵，直接求解 minimax 很难。如果假设这些 Hessian 可以同时对角化，那么每个特征方向 u_j 互不耦合，整个问题就变成“给每个方向选一个标量 λ_j^t ”的问题。这样才能用 KKT 条件推出 Proposition 5.2 的闭式水位解。

2.8 Taylor 展开、一阶最优性和曲率

一维 Taylor 展开是

$$f(a+h) = f(a) + f'(a)h + \frac{1}{2}f''(a)h^2 + O(h^3).$$

多维情形中，若 w 是向量，在点 w_0 附近展开：

$$f(w) = f(w_0) + \nabla f(w_0)^\top (w - w_0) + \frac{1}{2}(w - w_0)^\top \nabla^2 f(w_0)(w - w_0) + O(\|w - w_0\|^3).$$

这里：

- $\nabla f(w_0)$ 是梯度，一阶导数向量。
- $\nabla^2 f(w_0)$ 是 Hessian，二阶导数组成的矩阵。
- 曲率通常就指二阶导数或 Hessian。曲率大表示函数在这个方向变化很快，参数稍微动一点损失就变很多。

一阶最优性条件是：如果可微函数 $f(w)$ 在内部点 w^* 取得局部最小值，那么

$$\nabla f(w^*) = 0.$$

直观上，最小点附近不能再有“下降方向”，所以所有一阶方向导数都为 0。论文里每次写

$$\nabla_w \mathcal{L}(w_t, Z_t + \eta_t) + H_t(w_t - w_{t-1}) = 0$$

就是对正则化目标

$$\mathcal{L}(w, Z_t + \eta_t) + \frac{1}{2} \|w - w_{t-1}\|_{H_t}^2$$

求梯度并令其为 0。第二项的梯度是

$$\nabla_w \frac{1}{2} (w - w_{t-1})^\top H_t (w - w_{t-1}) = H_t (w - w_{t-1}),$$

这里使用了 H_t 对称这一事实。

2.9 为什么会出现 Hessian、伪逆和混合二阶导

很多公式看起来复杂，是因为论文把“数据扰动如何影响参数更新”局部线性化。若

$$Q_t = \nabla_{ww}^2 \mathcal{L}(w_t^*, Z_t), \quad G_t = \nabla_{wZ}^2 \mathcal{L}(w_t^*, Z_t), \quad S_t = Q_t + H_t,$$

那么：

- Q_t 是当前任务损失对参数的曲率；
- G_t 衡量数据 Z_t 变化如何改变参数梯度；
- $S_t = Q_t + H_t$ 是“数据曲率 + 正则化曲率”；
- S_t^+ 是 Moore-Penrose 伪逆，用来处理 S_t 不满秩的情况。

局部看，投毒先通过 $G_t \eta_t$ 改变梯度，再通过 S_t^+ 转化为参数偏移。所以敏感矩阵经常长成

$$S_t^+ G_t = (\nabla_{ww}^2 \mathcal{L}_t + H_t)^+ \nabla_{wZ}^2 \mathcal{L}_t.$$

这里的“敏感矩阵”指的是：输入一个数据扰动 η_t ，它输出由此造成的参数偏移或风险偏移。若这个矩阵在某个方向上放大倍数很大，攻击者就会优先沿这个方向投毒。

为什么是“数据曲率 + 正则化曲率” $S_t = Q_t + H_t$ ？因为总训练目标是

$$\mathcal{L}(w, Z_t) + \frac{1}{2} \|w - w_{t-1}\|_{H_t}^2.$$

第一项对 w 的 Hessian 是 Q_t ，第二项对 w 的 Hessian 是 H_t 。两者相加就是总目标对参数的局部二阶变化：

$$\nabla_{ww}^2 \left[\mathcal{L}(w, Z_t) + \frac{1}{2} \|w - w_{t-1}\|_{H_t}^2 \right] = Q_t + H_t.$$

为什么 $G_t = \nabla_{wZ}^2 \mathcal{L}$ 是“先对 w 再对 Z ”？因为最优性条件首先是关于参数梯度的：

$$\nabla_w \mathcal{L}(w, Z) = 0.$$

当数据从 Z_t 变成 $Z_t + \eta_t$ 时，真正受影响的是这个参数梯度。于是我们看“参数梯度 $\nabla_w \mathcal{L}$ 对数据 Z 的导数”，这就是混合导数

$$\nabla_Z (\nabla_w \mathcal{L}) = \nabla_{wZ}^2 \mathcal{L}.$$

在足够光滑时，先对 w 再对 Z 或先对 Z 再对 w 本质上是同一个混合二阶信息；论文的写法强调它是“数据扰动如何改变参数梯度”。

2.10 Moore-Penrose 伪逆是什么

普通逆矩阵 A^{-1} 只有在 A 是方阵且满秩时才存在。但机器学习里常有过参数化模型, Hessian 可能奇异或不满秩。这时方程

$$Ax = b$$

可能没有唯一解, 甚至没有精确解。Moore-Penrose 伪逆 A^+ 给出一个统一处理方式:

- 如果 A 可逆, 那么 $A^+ = A^{-1}$ 。
- 如果 $Ax = b$ 有很多解, A^+b 是范数最小的解。
- 如果没有精确解, A^+b 给出最小二乘意义下的解。

论文里出现 S_t^+ 是因为线性化后要解

$$S_t(w_t - w_t^*) \approx \text{某个由历史项和投毒项组成的向量}.$$

若 S_t 不可逆, 就不能写 S_t^{-1} , 只能写更一般的 S_t^+ 。

为什么说“投毒先影响梯度, 再通过伪逆变成参数偏移”? 因为训练后的参数由一阶最优性条件决定。数据一变, 梯度方程的右边先变; 为了重新满足“梯度为 0”, 参数必须移动。局部线性化后这个关系就是

$$S_t \cdot (\text{参数移动}) + G_t \cdot (\text{数据扰动}) \approx 0,$$

所以

$$\text{参数移动} \approx -S_t^+ G_t \cdot (\text{数据扰动}).$$

2.11 Kronecker 积、 I_{p_2} 和最大奇异方向

I_{p_2} 是 $p_2 \times p_2$ 的单位矩阵。例如 $p_2 = 3$ 时,

$$I_3 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}.$$

Kronecker 积 $\otimes$ 是一种把两个矩阵扩展成大矩阵的运算。若

$$A = \begin{bmatrix} a & b \\ c & d \end{bmatrix}, \quad B = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix},$$

则

$$A \otimes B = \begin{bmatrix} aB & bB \\ cB & dB \end{bmatrix}.$$

在线性回归里, 如果输出 y 是 p_2 维向量, 参数 w 是矩阵。为了使用普通向量公式, 论文把 w 拉直成 $\text{vec}(w)$, 并用

$$\mathbf{X}_t = I_{p_2} \otimes X_t$$

构造一个大设计矩阵, 使得

$$\text{vec}(Y_t) = \mathbf{X}_t \text{vec}(w^*) + \text{vec}(\varepsilon_t).$$

任意矩阵 A 都可以做奇异值分解

$$A = U\Sigma V^\top,$$

其中 Σ 对角线上的非负数叫奇异值：

$$\sigma_1 \geq \sigma_2 \geq \cdots \geq 0.$$

最大奇异值 σ_1 表示

$$\max_{\|x\|_2=1} \|Ax\|_2.$$

达到这个最大值的输入方向 v_1 就是最大右奇异方向。攻击者若有预算 $\mathbb{E}\|\eta\|^2 \leq M$ ，而目标近似为 $\mathbb{E}\|A\eta\|^2$ ，那么把扰动放在 v_1 方向最划算，因为它被 A 放大最多。

2.12 线性回归设置

为了得到闭式证明，论文后半部分使用多输出线性回归：

$$Y_t = X_t w^\star + \varepsilon_t, \quad \mathbb{E}[\varepsilon_t^i | x_t^i] = 0, \quad \mathbb{E}[\varepsilon_t^i (\varepsilon_t^i)^\top | x_t^i] = \sigma^2 I. \quad (3)$$

平方损失是

$$\ell(w, (x, y)) = \frac{1}{2} \|x^\top w - y\|_2^2.$$

论文在这个设置下把参数矩阵向量化：

$$\mathbf{w}_t = \text{vec}(w_t), \quad \mathbf{X}_t = I_{p_2} \otimes X_t.$$

这里的 $\otimes$ 是 Kronecker 积。它的作用是把多输出线性回归写成普通向量形式：

$$\text{vec}(Y_t) = \mathbf{X}_t \text{vec}(w^\star) + \text{vec}(\varepsilon_t).$$

3 进一步答疑：把概念和例子补齐

3.1 顺序到来的任务里，怎么谈全局最优

在 CL 过程中，算法通常不能真正求出最终全局最优，因为它在第 t 步只看到了 $1, \dots, t$ 的任务，还不知道未来任务 $t+1, \dots, T$ 。论文里的全局最优更多是一个评价基准：

$$w_{\text{glob},T}^\star \in \arg \min_w \sum_{s=1}^T \mathbb{E}_{z \sim \mathcal{D}_s} [\ell(w, z)].$$

它表示“如果所有任务都已经给出，并且可以联合训练，最好的模型是什么”。

如果只看已经到来的任务，也可以定义一个随时间变化的在线最优：

$$w_{\text{glob},t}^\star \in \arg \min_w \sum_{s=1}^t \mathbb{E}_{z \sim \mathcal{D}_s} [\ell(w, z)].$$

这个 $w_{\text{glob},t}^\star$ 一般会随 t 改变，因为新任务加入后，优化目标变了。

所以要区分三类“最优点”：

- $w_{\text{glob},T}^*$: 最终所有任务的全局最优，主要用于评价。
- $w_{\text{glob},t}^*$: 截至第 t 个任务的全局最优，会随任务到来变化。
- w_t^* : 只针对第 t 个任务本身的最优点，

$$w_t^* \in \arg \min_w \mathcal{L}(w, Z_t).$$

它不是累计任务的最优，而是单任务最优。

在论文的线性回归理论部分，作者额外假设存在一个共享真实参数 w^* ，所有任务都由

$$Y_t = X_t w^* + \varepsilon_t$$

生成。这个 w^* 默认不随 t 改变。一般 CL 情形里不同任务可以有不同 w_t^* ，但线性理论为了得到闭式收敛界，使用了共享 w^* 的简化模型。

3.2 为什么最优解可能不唯一，最小范数是什么意思

最优解不唯一的意思是：可能有很多个 w 都让损失达到同样的最小值。最简单的例子是欠定线性回归。假设只有一个方程

$$w_1 + w_2 = 1.$$

那么

$$(w_1, w_2) = (1, 0), (0, 1), (1/2, 1/2)$$

都能完全拟合数据。它们都是最优解。

范数就是“大小”。例如向量 $w = (w_1, w_2)$ 的二范数是

$$\|w\|_2 = \sqrt{w_1^2 + w_2^2}.$$

如果最优解有很多个，最小范数解就是在所有最优解里选长度最短的那个：

$$\arg \min_w \|w\|_2 \quad \text{s.t. } w \text{ 已经达到最小损失.}$$

这样做可以让目标模型唯一化，也常常对应更平滑或更简单的模型。

3.3 论文到底用不用平方损失

论文前面的系统模型写得比较一般，用任意损失 $\ell(w, z)$ 表达 CL 和攻击框架。后面的严格证明，尤其是 T2T 和鲁棒特征防御的闭式推导，使用的是平方损失：

$$\ell(w, (x, y)) = \frac{1}{2} \|x^\top w - y\|_2^2.$$

原因是平方损失的梯度、Hessian、线性回归递推都能写成显式矩阵公式。

3.4 H_t 的维度怎么确定

如果参数 $w \in \mathbb{R}^p$ 是一个 p 维向量，那么

$$H_t \in \mathbb{R}^{p \times p}.$$

这是由正则化项的形状决定的：

$$\|w - w_{t-1}\|_{H_t}^2 = (w - w_{t-1})^\top H_t (w - w_{t-1}).$$

其中 $w - w_{t-1}$ 是 $p \times 1$ ，左边转置是 $1 \times p$ 。为了最后得到一个标量， H_t 必须是 $p \times p$ 。

在线性回归多输出情形，原始参数 $w \in \mathbb{R}^{p_1 \times p_2}$ 是矩阵。向量化后

$$\text{vec}(w) \in \mathbb{R}^{p_1 p_2},$$

所以这时

$$H_t \in \mathbb{R}^{p_1 p_2 \times p_1 p_2}.$$

3.5 全局超额风险和正则化更新公式的关系

全局超额风险是评价指标：

$$\mathcal{R}_T(w_T) = \text{模型 } w_T \text{ 比最终全局最优差多少}.$$

正则化更新公式是训练算法：

$$w_t \in \arg \min_w \left\{ \mathcal{L}(w, Z_t) + \frac{1}{2} \|w - w_{t-1}\|_{H_t}^2 \right\}.$$

二者不是同一个东西。理想上我们想直接最小化全局风险，但 CL 中旧任务数据和未来任务不可用，所以算法只能用“当前任务经验损失 + 不要偏离旧模型太远”的方式间接控制最终全局风险。

3.6 label poisoning 是训练阶段攻击吗

是的，label poisoning 是训练阶段攻击。攻击者不是在测试时改输入，而是在模型训练时提供被污染的数据或标签。

现实例子包括：

- 众包标注平台中，恶意标注者提交错误标签。
- 联邦学习或在线学习中，某些客户端上传带错误标签的数据。
- 用户反馈系统中，模型把用户提供的反馈当作新训练标签，而攻击者伪造反馈。
- 医疗、BCI、传感器系统中，训练数据标签来自人工或外部系统，攻击者污染标签记录。

所以“正常使用的模型是否接受用户 label”取决于应用。有些系统只接收人工标注数据，有些系统会把用户反馈、交互结果或弱监督信号纳入后续训练。一旦训练管线信任这些标签，就存在 label poisoning 风险。

3.7 零均值扰动是否代表分布不变

不代表。零均值只表示平均方向不变：

$$\mathbb{E}[\tilde{\eta}_t \mid \mathcal{I}_t] = 0.$$

它不保证整个分布不变。一个简单例子：

$$\tilde{\eta} = \begin{cases} +10, & \text{概率 } 1/2, \\ -10, & \text{概率 } 1/2. \end{cases}$$

它的均值是 0，但方差很大，数据会变得更分散、更噪。对训练来说，方差增大会让梯度更抖、估计更不稳定、收敛更慢，甚至让模型沿脆弱方向产生大误差。

所以论文的 **non-shifted attack** 不是说数据分布完全不变，而是说“不改变条件均值”。它仍然可以改变方差、尾部、相关结构等。

3.8 攻击者知道什么

论文采用强攻击者假设：攻击者知道当前 CL 模型状态和当前数据，可以策略性选择扰动。记号

$$\mathcal{I}_t$$

表示攻击者选择扰动时可用的信息，通常包括历史、当前模型状态和当前任务数据。

这不一定表示模型系统真的保存了所有旧数据；它是理论中的强对手建模。用强对手证明防御有效，结论更保守。如果现实攻击者不知道这么多，防御通常只会更容易。

3.9 这些矩阵都是 Hessian 吗

不是。论文里有几类矩阵：

- $Q_t = \nabla_{ww}^2 \mathcal{L}(w_t^*, Z_t)$ ：这是 Hessian，表示任务损失对参数 w 的二阶导。
- H_t ：这是正则化矩阵，不是从数据损失直接求 Hessian 得到的，但它是正则化项的 Hessian。
- $S_t = Q_t + H_t$ ：这是总目标的局部 Hessian。
- $G_t = \nabla_{wZ}^2 \mathcal{L}(w_t^*, Z_t)$ ：这是混合二阶导，表示数据变化如何影响参数梯度，不是单纯对 w 的 Hessian。
- $P_t = \sum_{s=1}^t Q_s$ ：这是累计 Hessian，用来衡量模型偏移对所有已见任务损失的总影响。

3.10 KKT 条件是什么

KKT 条件是带约束优化的一阶最优性条件。它把“目标函数最小”和“约束满足”同时写出来。例如问题

$$\min_x f(x) \quad \text{s.t.} \quad g(x) \leq 0$$

的拉格朗日函数是

$$\mathcal{J}(x, \lambda) = f(x) + \lambda g(x), \quad \lambda \geq 0.$$

KKT 条件包括：

- stationarity: $\nabla_x \mathcal{J}(x, \lambda) = 0$;
- primal feasibility: $g(x) \leq 0$;
- dual feasibility: $\lambda \geq 0$;
- complementary slackness: $\lambda g(x) = 0$ 。

Proposition 5.2 中的 protected set 就是通过 KKT 条件判断哪些方向的攻击敏感度约束是“活跃”的。

3.11 为什么向量 Taylor 展开要有转置

若 $w \in \mathbb{R}^p$, 则 $w - w_0$ 是 $p \times 1$ 向量, Hessian $\nabla^2 f(w_0)$ 是 $p \times p$ 矩阵。二阶项必须是标量, 所以写成

$$(w - w_0)^\top \nabla^2 f(w_0)(w - w_0).$$

维度是

$$(1 \times p)(p \times p)(p \times 1) = 1 \times 1.$$

这就是为什么前面要有转置。

3.12 一阶最优性等式不能随便写

等式

$$\nabla_w \mathcal{L}(w_t, Z_t + \eta_t) + H_t(w_t - w_{t-1}) = 0$$

不是随便写的, 也不是因为“各阶导数都为 0”。它只表示: w_t 是下面这个正则化训练目标的极小点:

$$J_t(w) = \mathcal{L}(w, Z_t + \eta_t) + \frac{1}{2}(w - w_{t-1})^\top H_t(w - w_{t-1}).$$

为什么会突然出现这个目标? 因为这就是论文一开始定义的正则化式 CL 更新:

当前任务损失 + 不要离上一轮模型太远的惩罚。

没有攻击时当前数据是 Z_t ; 有投毒时训练系统实际收到的是 $Z_t + \eta_t$, 所以当前任务损失从 $\mathcal{L}(w, Z_t)$ 变成 $\mathcal{L}(w, Z_t + \eta_t)$ 。正则化项不变, 因为它是算法自己加的稳定项。

对 $J_t(w)$ 求梯度:

$$\nabla_w J_t(w) = \nabla_w \mathcal{L}(w, Z_t + \eta_t) + H_t(w - w_{t-1}).$$

这个求导分两部分:

- 第一部分 $\mathcal{L}(w, Z_t + \eta_t)$ 对 w 的导数, 就是 $\nabla_w \mathcal{L}(w, Z_t + \eta_t)$ 。
- 第二部分是二次惩罚。令 $u = w - w_{t-1}$, 则

$$\frac{1}{2}u^\top H_t u$$

对 u 的导数是 $H_t u$; 又因为 $u = w - w_{t-1}$, 对 w 求导还是 $H_t(w - w_{t-1})$ 。

在最优点 $w = w_t$ ，一阶最优性条件给出

$$\nabla_w J_t(w_t) = 0,$$

于是得到论文的等式。这里为 0 的是一阶导数/梯度，不是所有高阶导数。二阶导数通常不为 0，它反而给出曲率信息。

第二项的 Hessian 为什么是 H_t ？因为

$$\nabla_w \frac{1}{2} (w - w_{t-1})^\top H_t (w - w_{t-1}) = H_t (w - w_{t-1}),$$

再对 w 求一次导数就是

$$\nabla_w^2 \frac{1}{2} (w - w_{t-1})^\top H_t (w - w_{t-1}) = H_t.$$

3.13 G_t 的作用用一个线性回归例子看

平方损失下

$$\mathcal{L}(w, X, Y) = \frac{1}{2n} \|Xw - Y\|_2^2.$$

对 w 求梯度：

$$\nabla_w \mathcal{L}(w, X, Y) = \frac{1}{n} X^\top (Xw - Y).$$

如果 label 被投毒， Y 变成 $Y + \eta$ ，那么

$$\nabla_w \mathcal{L}(w, X, Y + \eta) = \frac{1}{n} X^\top (Xw - Y - \eta) = \nabla_w \mathcal{L}(w, X, Y) - \frac{1}{n} X^\top \eta.$$

所以 label 扰动对梯度的影响是

$$-\frac{1}{n} X^\top \eta.$$

这就是 $G_t \text{vec}(\eta_t)$ 在一般公式里的作用：它把“数据扰动”转换成“梯度扰动”。

3.14 奇异、不满秩会造成什么影响

矩阵奇异表示它不可逆。对方阵 A ，奇异等价于

$$\det(A) = 0.$$

$\det(A)$ 叫行列式，是一个把方阵映射成数字的运算。二维矩阵

$$A = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$$

的行列式是

$$\det(A) = ad - bc.$$

几何上， $|\det(A)|$ 表示这个矩阵把面积放大了多少倍。如果 $\det(A) = 0$ ，说明某个方向被压扁，面积变成 0，信息丢了，所以矩阵没有逆。

奇异也等价于存在非零向量 v 使得

$$Av = 0.$$

这说明某些方向被矩阵压成 0，信息丢失。

不满秩表示矩阵的独立行或列不够多。比如

$$A = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}$$

第二行是第一行的 2 倍，所以秩只有 1，不满秩，也不可逆。

在优化里，Hessian 奇异意味着某些方向曲率为 0，损失在这些方向很平坦。结果是：

- 最优解可能不唯一；
- 普通逆矩阵不存在；
- 参数扰动方程不能用 S_t^{-1} 解，只能用伪逆 S_t^+ 。

3.15 为什么把 w 拉直成 $\text{vec}(w)$

多输出线性回归中， w 本来是矩阵：

$$w \in \mathbb{R}^{p_1 \times p_2}.$$

当然可以直接用矩阵微积分推导，但写均值、协方差、Hessian、minimax 时会很繁琐。把矩阵拉直成向量

$$\text{vec}(w) \in \mathbb{R}^{p_1 p_2}$$

后，就可以统一使用普通向量公式：

$$\text{Cov}(\text{vec}(w_t - w^*)), \quad H_t \in \mathbb{R}^{p_1 p_2 \times p_1 p_2}.$$

这只是记号和计算上的方便，不是改变模型本身。

3.16 为什么要做奇异值分解

奇异值分解把矩阵 A 写成

$$A = U \Sigma V^\top.$$

可以理解成三步：

先旋转输入($V^\top$)，按不同轴缩放(Σ)，再旋转输出(U)。

如果

$$\Sigma = \text{diag}(5, 1),$$

那么第一个奇异方向会被放大 5 倍，第二个方向只放大 1 倍。攻击者要最大化 $\|A\eta\|$ ，当然会把预算放到第一个方向。

这就是论文说“最大奇异方向”的原因。它不是为了分解矩阵好看，而是为了解

$$\max_{\mathbb{E}\|\eta\|^2 \leq M} \mathbb{E}\|A\eta\|^2.$$

3.17 噪声协方差公式是什么意思

论文假设

$$\mathbb{E}[\varepsilon_t^i (\varepsilon_t^i)^\top \mid x_t^i] = \sigma^2 I.$$

这里 ε_t^i 是第 i 个样本的输出噪声向量。如果输出是一维，公式退化成

$$\mathbb{E}[(\varepsilon_t^i)^2 \mid x_t^i] = \sigma^2.$$

如果输出是多维，它表示噪声协方差是 $\sigma^2 I$ ，即：

- 每个输出维度的噪声方差都是 σ^2 ；
- 不同输出维度之间不相关；
- 噪声强度不依赖具体输入 x_t^i 。

3.18 为什么写 P_t

在 Proposition 2.4 中，

$$P_t = \sum_{\tau=1}^t Q_\tau, \quad Q_\tau = \nabla_{ww}^2 \mathcal{L}(w_\tau^*, Z_\tau).$$

它来自把所有已见任务的经验损失都做二阶 Taylor 展开：

$$\sum_{\tau=1}^t \frac{1}{2} (w_t - w_\tau^*)^\top Q_\tau (w_t - w_\tau^*).$$

如果只看攻击造成的共同参数偏移 δ ，这些二次项会累加成

$$\frac{1}{2} \delta^\top \left(\sum_{\tau=1}^t Q_\tau \right) \delta = \frac{1}{2} \|\delta\|_{P_t}^2.$$

所以 P_t 是“所有旧任务对参数偏移的累计惩罚权重”。

3.19 从正则化目标到论文式 (4) 的思路

论文式 (4) 是攻防问题：

$$\min_{H_t} \max_{\hat{\eta}_t, \tilde{\eta}_t} \mathcal{R}_t(w_t) \quad \text{s.t.} \quad \mathbb{E}[\|\hat{\eta}_t + \tilde{\eta}_t\|_F^2] \leq M.$$

它不是从正则化目标“直接求导”得到的，而是把两件事合起来建模：

- 给定 H_t 和攻击扰动，模型 w_t 由正则化训练目标产生；
- 防御者想让最终风险小，攻击者想让最终风险大。

所以正则化目标决定 w_t 如何依赖 H_t, η_t ；式 (4) 再把这种依赖放进风险 $\mathcal{R}_t(w_t)$ ，形成外层的 min-max 游戏。

3.20 攻击预算为什么用 Frobenius 范数

一个任务里有 n_t 个样本, 每个样本的标签可能是多维的, 所以 label perturbation η_t 通常是矩阵:

$$\eta_t \in \mathbb{R}^{n_t \times p_2}.$$

Frobenius 范数

$$\|\eta_t\|_F^2 = \sum_{i,j} (\eta_t^{i,j})^2$$

就是把所有样本、所有输出维度上的扰动能量加起来。它自然表示“这次攻击总共用了多少扰动预算”。

3.21 攻击预算为什么会放到最大奇异方向

把 Proposition 2.4 的主导攻击项抽象成

$$\max_{\eta} \mathbb{E} \|A\eta\|_2^2 \quad \text{s.t.} \quad \mathbb{E} \|\eta\|_2^2 \leq M,$$

其中

$$A = P_t^{1/2} S_t^+ G_t.$$

若攻击是随机零均值扰动, 令协方差

$$\Sigma = \mathbb{E}[\eta\eta^\top], \quad \text{tr}(\Sigma) = \mathbb{E} \|\eta\|_2^2 \leq M.$$

目标函数变成

$$\mathbb{E} \|A\eta\|_2^2 = \mathbb{E}[\eta^\top A^\top A \eta] = \text{tr}(A^\top A \Sigma).$$

设 $A^\top A$ 的最大特征值是 $\lambda_{\max}$, 对应单位特征向量是 v_1 。因为 $\Sigma \succeq 0$, 在预算 $\text{tr}(\Sigma) \leq M$ 下, 最大化

$$\text{tr}(A^\top A \Sigma)$$

的最优选择是

$$\Sigma = M v_1 v_1^\top.$$

也就是说, 攻击者把全部方差预算放在 v_1 方向。这个 v_1 正是 A 的最大右奇异方向, 因为 $A^\top A$ 的特征向量就是 A 的右奇异向量。

4 命题 2.4 / 附录命题 A.1: 攻击目标的近似公式

4.1 结论形式

令

$$\mathcal{L}(w, Z_t) = \frac{1}{n_t} \sum_{z \in D_t} \ell(w, z), \quad w_t^* \in \arg \min_w \mathcal{L}(w, Z_t),$$

并记

$$P_t = \sum_{s=1}^t \nabla_{ww}^2 \mathcal{L}(w_s^*, Z_s).$$

对 non-shifted 攻击 $\tilde{\eta}_t$, 论文得到近似目标:

$$\begin{aligned} \max_{\tilde{\eta}_t} \quad & \frac{1}{2} \mathbb{E} \left[\left\| (\nabla_{ww}^2 \mathcal{L}_t + H_t)^+ \nabla_{wZ}^2 \mathcal{L}_t \text{vec}(\tilde{\eta}_t) \right\|_{P_t}^2 \right] + \text{高阶余项} \\ \text{s.t.} \quad & \mathbb{E}[\|\tilde{\eta}_t\|_F^2] \leq M. \end{aligned} \quad (4)$$

其中 $\mathcal{L}_t$ 是 $\mathcal{L}(w_t^*, Z_t)$ 的简写。

这条公式表达了一个核心事实: 攻击者会把预算放到

$$P_t^{1/2} (\nabla_{ww}^2 \mathcal{L}_t + H_t)^+ \nabla_{wZ}^2 \mathcal{L}_t$$

的最大奇异方向上, 因为这个方向让相同扰动造成最大的累计风险增量。

4.2 证明拆解

第一步: 用经验风险替代真实风险。 真实风险 $\mathcal{R}_t(w_t)$ 依赖未知分布 $\mathcal{D}_1, \dots, \mathcal{D}_t$ 。CL 中旧数据也不可访问。因此论文先用已经出现任务的经验损失和来近似:

$$\sum_{\tau=1}^t \mathcal{L}(w_t, Z_\tau).$$

第二步: 在每个任务最优点 w_τ^* 附近 Taylor 展开。 因为 w_τ^* 是任务 τ 的经验损失极小点,

$$\nabla_w \mathcal{L}(w_\tau^*, Z_\tau) = 0.$$

所以二阶展开给出

$$\sum_{\tau=1}^t \mathcal{L}(w_t, Z_\tau) = \sum_{\tau=1}^t \mathcal{L}(w_\tau^*, Z_\tau) + \frac{1}{2} \sum_{\tau=1}^t (w_t - w_\tau^*)^\top Q_\tau (w_t - w_\tau^*) + O\left(\sum_{\tau=1}^t \|w_t - w_\tau^*\|_2^3\right), \quad (5)$$

其中 $Q_\tau = \nabla_{ww}^2 \mathcal{L}(w_\tau^*, Z_\tau)$ 。

第三步: 把投毒导致的更新写成局部线性方程。 带投毒数据 $Z_t + \eta_t$ 的一阶最优性条件是

$$\nabla_w \mathcal{L}(w_t, Z_t + \eta_t) + H_t(w_t - w_{t-1}) = 0.$$

在 (w_t^*, Z_t) 附近展开:

$$\nabla_w \mathcal{L}(w_t, Z_t + \eta_t) \approx \underbrace{\nabla_w \mathcal{L}(w_t^*, Z_t)}_{=0} + \underbrace{\nabla_{ww}^2 \mathcal{L}(w_t^*, Z_t)}_{Q_t} (w_t - w_t^*) + \underbrace{\nabla_{wZ}^2 \mathcal{L}(w_t^*, Z_t)}_{G_t} \text{vec}(\eta_t).$$

第一项为 0, 是因为 w_t^* 是干净任务 t 的经验损失最小点。把这个展开代回一阶最优性条件, 就得到

$$Q_t(w_t - w_t^*) + G_t \text{vec}(\eta_t) + H_t(w_t - w_{t-1}) + O(\|w_t - w_t^*\|_2^2 + \|\eta_t\|_F^2) = 0, \quad (6)$$

其中 $G_t = \nabla_{wZ}^2 \mathcal{L}(w_t^*, Z_t)$ 。下面把 (6) 整理成论文使用的形式。目标是求 $w_t - w_\tau^*$, 其中 $\tau \leq t$ 是任意一个历史任务。令

$$a_\tau := w_t - w_\tau^*.$$

那么

$$w_t - w_t^* = a_\tau - (w_t^* - w_\tau^*), \quad w_t - w_{t-1} = a_\tau - (w_{t-1} - w_\tau^*).$$

代入 (6):

$$Q_t[a_\tau - (w_t^* - w_\tau^*)] + G_t \text{vec}(\eta_t) + H_t[a_\tau - (w_{t-1} - w_\tau^*)] + \text{高阶项} = 0.$$

把含 a_τ 的项放左边, 其余项放右边:

$$(Q_t + H_t)a_\tau = Q_t(w_t^* - w_\tau^*) + H_t(w_{t-1} - w_\tau^*) - G_t \text{vec}(\eta_t) + \text{高阶项}.$$

记 $S_t = Q_t + H_t$ 。若 S_t 可逆, 就左乘 S_t^{-1} ; 若不可逆, 就用伪逆 S_t^+ 。于是

$$w_t - w_\tau^* = S_t^+ [Q_t(w_t^* - w_\tau^*) + H_t(w_{t-1} - w_\tau^*) - G_t \text{vec}(\eta_t)] + O(\|w_t - w_t^*\|_2^2 + \|\eta_t\|_F^2), \quad (7)$$

这就是局部线性方程的来源。

第四步: 代回二次风险。 把 (7) 代入 (5), 所有和 η_t 无关的项对攻击者不重要, 可以丢掉。留下的攻击相关部分是

$$\begin{aligned} & \frac{1}{2} \|S_t^+ G_t \text{vec}(\eta_t)\|_{P_t}^2 - \text{vec}(\eta_t)^\top G_t^\top S_t^+ \sum_{\tau=1}^t Q_\tau S_t^+ [Q_t(w_t^* - w_\tau^*) + H_t(w_{t-1} - w_\tau^*)] \\ & + O(\|\eta_t\|_F^2 + \|w_t - w_t^*\|_2^2) + O\left(\sum_{\tau=1}^t \|w_t - w_\tau^*\|_2^3\right). \end{aligned} \quad (8)$$

这一行可以按下面的方式一步步看。先定义

$$b_\tau = S_t^+ [Q_t(w_t^* - w_\tau^*) + H_t(w_{t-1} - w_\tau^*)], \quad r_t = S_t^+ G_t \text{vec}(\eta_t).$$

那么忽略高阶项时

$$w_t - w_\tau^* = b_\tau - r_t.$$

二次型记号是

$$\|x\|_{Q_\tau}^2 = x^\top Q_\tau x.$$

所以 Taylor 二次项变成

$$\frac{1}{2} \sum_{\tau=1}^t \|b_\tau - r_t\|_{Q_\tau}^2.$$

展开一个平方:

$$\|b_\tau - r_t\|_{Q_\tau}^2 = (b_\tau - r_t)^\top Q_\tau (b_\tau - r_t) = b_\tau^\top Q_\tau b_\tau - 2r_t^\top Q_\tau b_\tau + r_t^\top Q_\tau r_t.$$

三类项的含义是:

- $b_\tau^\top Q_\tau b_\tau$: 不含 η_t , 攻击者无法通过当前扰动改变, 分析攻击目标时可以丢掉。
- $-2r_t^\top Q_\tau b_\tau$: 含一个 r_t , 所以是关于 η_t 的线性项。
- $r_t^\top Q_\tau r_t$: 含两个 r_t , 所以是关于 η_t 的二次项。

把二次项对 τ 求和:

$$\frac{1}{2} \sum_{\tau=1}^t r_t^\top Q_\tau r_t = \frac{1}{2} r_t^\top \left(\sum_{\tau=1}^t Q_\tau \right) r_t = \frac{1}{2} \|r_t\|_{P_t}^2.$$

再代回 $r_t = S_t^+ G_t \text{vec}(\eta_t)$, 就得到

$$\frac{1}{2} \|S_t^+ G_t \text{vec}(\eta_t)\|_{P_t}^2.$$

线性项对 τ 求和后就是 (8) 中的第二项。由于 S_t 是对称矩阵, 伪逆 S_t^+ 也可按对称矩阵处理, 所以转置记号可以简化成论文里的形式。

第五步: 为什么 non-shifted 攻击没有线性项。 若

$$\eta_t = \hat{\eta}_t + \tilde{\eta}_t, \quad \mathbb{E}[\tilde{\eta}_t \mid Z_{1:t}, w_{t-1}] = 0,$$

把 $\eta_t = \tilde{\eta}_t$ 代入 (8)。其中第一项是二次型:

$$\frac{1}{2} \|S_t^+ G_t \text{vec}(\tilde{\eta}_t)\|_{P_t}^2.$$

第二项是线性项, 可以写成

$$-\text{vec}(\tilde{\eta}_t)^\top a_t,$$

其中 a_t 是由 $G_t, S_t, Q_\tau, w_t^*, w_\tau^*, w_{t-1}$ 组成的、在条件信息 $Z_{1:t}, w_{t-1}$ 下已经确定的向量。于是

$$\mathbb{E}[-\text{vec}(\tilde{\eta}_t)^\top a_t \mid Z_{1:t}, w_{t-1}] = -\mathbb{E}[\text{vec}(\tilde{\eta}_t) \mid Z_{1:t}, w_{t-1}]^\top a_t = 0.$$

所以对 non-shifted 攻击, 取期望后线性项消失, 主导项只剩

$$\frac{1}{2} \mathbb{E} \left[\|S_t^+ G_t \text{vec}(\tilde{\eta}_t)\|_{P_t}^2 \right],$$

这正是 (4)。shifted 攻击 $\hat{\eta}_t$ 会保留线性项, 所以它更危险: 它能直接把模型均值推向错误方向。

5 定理 3.1: 为什么有些攻击根本防不住

5.1 定理含义

论文证明: 存在一些问题实例, 使得任意正则化式 CL 方法 (2) 都无法保证收敛。两类攻击是:

- frequent + shifted;
- frequent + unbounded + non-shifted。

证明只需要构造一维线性回归反例。

反例证明的原理是: 如果一个结论声称“任何正则化式 CL 方法都能防住”, 那么只要找出一个非常简单的问题, 使得任意 H_t 选择都会失败, 就能推翻这个声称。一维问题已经足够, 因为正则化更新会退化成一个简单的加权平均:

$$\text{新模型} = \text{当前数据权重} \times \text{当前观测} + \text{旧模型权重} \times \text{旧模型}.$$

攻击者正是利用这个加权平均: 如果算法不断吸收新数据, 就会吸收攻击; 如果算法不吸收新数据, 又无法消除初始误差。

5.2 一维反例

设

$$p_1 = p_2 = n_t = 1, \quad x_t = 1, \quad y_t = w^* + \varepsilon_t,$$

平方损失 $\ell(w, z_t) = (w - y_t)^2$ 。这里 w^* 是真实的一维参数。因为 $x_t = 1$, 干净数据满足 $y_t = w^* + \varepsilon_t$, 所以如果没有噪声和攻击, 最好的模型就是 $w = w^*$ 。

若任务 t 被投毒, 训练标签变成 $y_t + \eta_t$ 。正则化更新目标是

$$\min_w \left\{ (w - (y_t + \eta_t))^2 + \frac{1}{2} H_t (w - w_{t-1})^2 \right\}.$$

对 w 求导并令其为 0:

$$2(w - (y_t + \eta_t)) + H_t(w - w_{t-1}) = 0.$$

展开:

$$(2 + H_t)w = 2(y_t + \eta_t) + H_t w_{t-1}.$$

因此

$$w_t = \frac{2}{2 + H_t}(y_t + \eta_t) + \frac{H_t}{2 + H_t} w_{t-1}.$$

论文说“吸收常数因子”, 意思是把常数 2 合并进正则化参数的记号里。因为这里要证明的是不可能性, 常数倍不影响结论, 于是等价写成

$$w_t = \frac{1}{1 + H_t}(y_t + \eta_t) + \frac{H_t}{1 + H_t} w_{t-1}.$$

定义

$$c_t = \frac{H_t}{1 + H_t} \in [0, 1],$$

则 $1 - c_t = 1/(1 + H_t)$ 。把 $y_t = w^* + \varepsilon_t$ 代入:

$$w_t = (1 - c_t)(w^* + \varepsilon_t + \eta_t) + c_t w_{t-1}.$$

两边减去 w^* :

$$w_t - w^* = c_t(w_{t-1} - w^*) + (1 - c_t)(\varepsilon_t + \eta_t) + (1 - c_t)w^* + c_t w^* - w^*.$$

最后三项中关于 w^* 的部分抵消, 因为

$$(1 - c_t)w^* + c_t w^* - w^* = 0.$$

因此

$$w_t - w^* = c_t(w_{t-1} - w^*) + (1 - c_t)(\varepsilon_t + \eta_t). \quad (9)$$

这个递推是整条证明的核心。

5.3 frequent shifted 攻击

令攻击每个任务, 并取常数偏移 $\eta_t = \Delta \neq 0$ 。设

$$m_t = \mathbb{E}[w_t - w^*],$$

由 (9) 得

$$m_t = c_t m_{t-1} + (1 - c_t) \Delta.$$

减去 Δ :

$$m_t - \Delta = c_t (m_{t-1} - \Delta),$$

这个式子每往前展开一次, 就多乘一个 c 。例如:

$$m_T - \Delta = c_T (m_{T-1} - \Delta) = c_T c_{T-1} (m_{T-2} - \Delta) = \cdots = \left(\prod_{t=1}^T c_t \right) (m_0 - \Delta).$$

而 $m_0 = \mathbb{E}[w_0 - w^*] = w_0 - w^*$, 所以

$$m_T = \Delta + \left(\prod_{t=1}^T c_t \right) (w_0 - w^* - \Delta).$$

现在分两种情况:

- 若 $\prod_{t=1}^T c_t \not\rightarrow 0$, 则即使无攻击无噪声, 初始偏差也不能被完全遗忘, 算法本来就不保证收敛。
- 若 $\prod_{t=1}^T c_t \rightarrow 0$, 则上式第二项趋于 0, 所以在 shifted 攻击下 $m_T \rightarrow \Delta$, 于是

$$\mathbb{E}[(w_T - w^*)^2] \geq (\mathbb{E}[w_T - w^*])^2 \rightarrow \Delta^2 > 0.$$

这里用的是

$$\mathbb{E}[X^2] = \text{Var}(X) + (\mathbb{E}X)^2 \geq (\mathbb{E}X)^2.$$

令 $X = w_T - w^*$ 。如果均值已经趋向 Δ , 那么平方误差的期望至少趋向 Δ^2 , 不可能收敛到 0。因此无论正则化策略如何选, 总有一种情形无法收敛。

5.4 frequent unbounded non-shifted 攻击

现在攻击仍然每个任务, 但取零均值独立扰动:

$$\mathbb{E}[\tilde{\eta}_t] = 0, \quad \mathbb{E}[\tilde{\eta}_t^2] = M_T, \quad M_T = \Omega(T).$$

$\mathbb{E}[\tilde{\eta}_t^2] = M_T$ 在一维零均值情况下就是“攻击扰动的方差等于 M_T ”。 $M_T = \Omega(T)$ 的意思是: 存在常数 $c > 0$ 和足够大的 T , 使得

$$M_T \geq cT.$$

也就是说, 单次攻击预算至少和任务总数 T 同阶增长, 所以这是 unbounded attack。

展开 (9):

$$w_T - w^* = \left(\prod_{r=1}^T c_r \right) (w_0 - w^*) + \sum_{s=1}^T \beta_{s,T} (\varepsilon_s + \tilde{\eta}_s),$$

其中

$$\beta_{s,T} = (1 - c_s) \prod_{r=s+1}^T c_r.$$

$\beta_{s,T}$ 来自反复代入递推。比如写到 $T = 3$:

$$\begin{aligned} w_3 - w^* &= c_3(w_2 - w^*) + (1 - c_3)(\varepsilon_3 + \tilde{\eta}_3) \\ &= c_3 c_2(w_1 - w^*) + c_3(1 - c_2)(\varepsilon_2 + \tilde{\eta}_2) + (1 - c_3)(\varepsilon_3 + \tilde{\eta}_3) \\ &= c_3 c_2 c_1(w_0 - w^*) + c_3 c_2(1 - c_1)(\varepsilon_1 + \tilde{\eta}_1) \\ &\quad + c_3(1 - c_2)(\varepsilon_2 + \tilde{\eta}_2) + (1 - c_3)(\varepsilon_3 + \tilde{\eta}_3). \end{aligned}$$

因此第 s 步噪声前面的系数就是“进入时的 $1 - c_s$ ”乘上“之后每一步保留下来的 c ”。

$\beta_{s,T}$ 的含义是: 第 s 步噪声进入模型时先乘当前数据权重 $1 - c_s$, 之后从 $s + 1$ 到 T 每一步又被旧模型保留权重 $c_{s+1}, \dots, c_T$ 继续传递, 所以总权重是

$$(1 - c_s)c_{s+1}c_{s+2} \cdots c_T.$$

当 $s = T$ 时, 后面已经没有 $c_{T+1}, \dots, c_T$ 可以乘。数学上把这种“没有任何项可乘”的乘积定义为 1, 叫空乘积:

$$\prod_{r=T+1}^T c_r = 1.$$

所以

$$\beta_{T,T} = 1 - c_T.$$

这些权重满足望远镜恒等式

$$\sum_{s=1}^T \beta_{s,T} = 1 - \prod_{r=1}^T c_r.$$

为什么叫望远镜? 因为

$$\beta_{s,T} = (1 - c_s) \prod_{r=s+1}^T c_r = \prod_{r=s+1}^T c_r - \prod_{r=s}^T c_r.$$

于是求和时中间项会一正一负相互抵消:

$$\begin{aligned} \sum_{s=1}^T \beta_{s,T} &= (c_2 \cdots c_T - c_1 c_2 \cdots c_T) + (c_3 \cdots c_T - c_2 c_3 \cdots c_T) + \cdots + (1 - c_T) \\ &= 1 - c_1 c_2 \cdots c_T = 1 - \prod_{r=1}^T c_r. \end{aligned}$$

如果 $\prod c_r \not\rightarrow 0$, 初始偏差仍然不消失; 否则

$$\sum_{s=1}^T \beta_{s,T} \rightarrow 1.$$

由 Cauchy 不等式

$$\sum_{s=1}^T \beta_{s,T}^2 \geq \frac{\left(\sum_{s=1}^T \beta_{s,T}\right)^2}{T} = \frac{(1 - \prod_{r=1}^T c_r)^2}{T}.$$

Cauchy 在这里用的是基础形式：

$$\left(\sum_{s=1}^T a_s \cdot 1 \right)^2 \leq \left(\sum_{s=1}^T a_s^2 \right) \left(\sum_{s=1}^T 1^2 \right) = T \sum_{s=1}^T a_s^2.$$

把 $a_s = \beta_{s,T}$ 代入并移项，就得到上面的下界。

攻击方差给最终风险贡献至少

$$M_T \sum_{s=1}^T \beta_{s,T}^2 \geq M_T \frac{(1 - \prod_{r=1}^T c_r)^2}{T}.$$

因为 $M_T = \Omega(T)$ ，右端不会趋于 0。定理得证。

说明 5.1. 这个反例很重要。正则化 CL 必须靠 $c_t < 1$ 逐步忘掉初始偏差；但一旦每一步都混入有偏或巨大方差攻击，这种“持续吸收新数据”的机制本身就会把攻击吸收进去。

6 T2T 防御：少量但强攻击的检测与证明

6.1 先不看公式：T2T 到底想做什么

T2T 的问题不是“模型有没有变”，而是“最近两个任务里有没有异常投毒”。只看

$$w_t - w_{t-1}$$

不够，因为这个更新可能同时混有三种来源：

- 当前任务 t 的正常学习信号；
- 当前或上一任务的投毒信号；
- 更早历史模型 w_{t-2} 留下的影响。

第三种历史影响会干扰判断。T2T 的核心就是：用连续两次更新互相对照，把共同的历史影响抵消掉，只留下最近两个任务造成的局部变化。

可以把两次更新写成一种口语化形式：

$$\text{当前更新} \approx A_t \times \text{旧历史状态} + \text{最近任务差异} + \text{最近投毒},$$

$$\text{上一次更新} \approx B_t \times \text{旧历史状态} + \text{上一任务投毒}.$$

这里的 A_t 和 B_t 不是随机构造的变量，它们是由正则化更新的线性化推出来的**历史传播矩阵**：

- A_t ：旧状态 w_{t-2} 经过任务 $t-1$ 再影响任务 t 的路径。
- B_t ：旧状态 w_{t-2} 影响上一轮更新 $w_{t-1} - w_{t-2}$ 的路径。

换句话说， A_t 和 B_t 描述的是“同一个历史状态分别在两次更新里长成什么样”。

那为什么检测分数要乘 D_t^1, D_t^2 ？因为当前更新里的历史项是 $A_t \times \text{旧历史状态}$ ，上一更新里的历史项是 $B_t \times \text{旧历史状态}$ 。它们形状不同，不能直接相减。于是我们找两个线性变换 D_t^1, D_t^2 ，让

$$D_t^1 A_t = D_t^2 B_t.$$

这样一来，两次更新经过 D_t^1, D_t^2 处理后，历史项变成同一个东西，相减时就消掉了。

所以 T2T 检测分数的逻辑是：

$$\text{检测分数} = \|\text{处理后的当前更新} - \text{处理后的上一次更新}\|.$$

如果没有攻击，这个差值主要来自相邻任务本身的正常差异和随机噪声，应该比较稳定；如果最近两个任务中有强投毒，这个差值会突然变大。

论文中的 C_t 也不是随机构造。它是为了在满足

$$D_t^1 A_t = D_t^2 B_t$$

的同时，让 D_t^1 尽量像 A_t^+ ，让 D_t^2 尽量像 B_t^+ 。直观上， A_t^+ 和 B_t^+ 是“尽量把 A_t, B_t 的影响反解回去”的工具；但只用伪逆不一定能让历史项完全抵消，所以论文加了 C_t 来修正。

$(I - B_t)$ 的作用也不是普通意义上“把长度归一化”。这里 I 是单位矩阵， $I - B_t$ 表示“保留原向量，再减去 B_t 能解释的那部分”。可以把它理解成一个线性过滤器：它削弱上一任务动力学已经能解释的分量，让检测分数更关注新出现的局部异常。论文把它放在 D_t^1, D_t^2 前面，是为了让两个投影后的更新处在更可比较的局部空间里。

如果你说的公式 16、17、18 对应这一段，那么它们的关系应这样读：

- 检测分数公式：定义“比较什么”。
- D_t^1, D_t^2, C_t 公式：定义“如何把两次更新变到同一空间再比较”。
- A_t, B_t 公式：说明“历史状态在两次更新里分别如何传播”。

先有检测目标，再有抵消历史项的需求，最后才有这些矩阵公式。

6.2 检测分数的设计

少量但强攻击的关键困难是：攻击任务未知，而且 shifted 攻击可以非常大。最自然的防御是检测异常任务并回滚。但只看

$$\|w_t - w_{t-1}\|$$

会有归因问题：大更新可能来自当前任务被攻击，也可能来自当前良性任务在纠正过去被攻击造成的偏差。

T2T 使用两个连续更新：

$$w_t - w_{t-1}, \quad w_{t-1} - w_{t-2}.$$

检测分数为

$$d_t = \|D_t^1(w_t - w_{t-1}) - D_t^2(w_{t-1} - w_{t-2})\|. \quad (10)$$

其中

$$D_t^1 = (I - B_t)(A_t^+ - C_t A_t^\top), \quad (11)$$

$$D_t^2 = (I - B_t)(B_t^+ + C_t B_t^\top), \quad (12)$$

$$C_t = (A_t^+ A_t - B_t^+ B_t)(A_t^\top A_t + B_t^\top B_t)^+, \quad (13)$$

而

$$A_t = (\nabla_{ww}^2 \mathcal{L}_t + H_t)^{-1} \nabla_{ww}^2 \mathcal{L}_t (\nabla_{ww}^2 \mathcal{L}_{t-1} + H_{t-1})^{-1} H_{t-1}, \quad (14)$$

$$B_t = (\nabla_{ww}^2 \mathcal{L}_{t-1} + H_{t-1})^{-1} \nabla_{ww}^2 \mathcal{L}_{t-1}. \quad (15)$$

6.3 引理 4.1：为什么这个分数能隔离最近两个任务

引理说：

$$D_t^1(w_t - w_{t-1}) - D_t^2(w_{t-1} - w_{t-2}) = E_t^1(w_t^* - w_{t-1}^*) + E_t^2 \text{vec}(\eta_{t-1}) + E_t^3 \text{vec}(\eta_t) + \mathcal{E}_t, \quad (16)$$

其中

$$\mathcal{E}_t = O(\|w_t - w_t^*\|^2) + O(\|w_{t-1} - w_{t-1}^*\|^2) + O(\|\eta_t\|^2 + \|\eta_{t-1}\|^2).$$

最重要的是：右边没有 w_{t-2} 的历史项。

6.4 证明关键：构造 $D_t^1 A_t = D_t^2 B_t$

从线性化更新可得到

$$\begin{aligned} w_t - w_{t-1} = & -A_t(w_{t-2} - w_t^*) + S_t^+ Q_t S_{t-1}^+ Q_{t-1}(w_t^* - w_{t-1}^*) \\ & + S_t^+ Q_t S_{t-1}^+ G_{t-1} \text{vec}(\eta_{t-1}) - S_t^+ G_t \text{vec}(\eta_t) + \text{高阶项}, \end{aligned} \quad (17)$$

$$w_{t-1} - w_{t-2} = -B_t(w_{t-2} - w_{t-1}^*) - S_{t-1}^+ G_{t-1} \text{vec}(\eta_{t-1}) + \text{高阶项}. \quad (18)$$

两式都含有历史状态 w_{t-2} 。为了消掉它，需要

$$D_t^1 A_t = D_t^2 B_t.$$

论文把 D_t^1, D_t^2 设计成下列最小二乘投影问题的解：

$$\min_{\bar{D}_t^1, \bar{D}_t^2} \|\bar{D}_t^1 - A_t^+\|_F^2 + \|\bar{D}_t^2 - B_t^+\|_F^2, \quad \text{s.t. } \bar{D}_t^1 A_t = \bar{D}_t^2 B_t.$$

解出来就是 (13) 中的形式，再乘上 $(I - B_t)$ 做归一化。代回 (17)-(18) 后，历史项抵消，只剩最近两个任务的任务差异和攻击项。

6.5 把 T2T 公式 10-25 连成一条推导链

这一小节按“为什么需要这个公式”的顺序讲，而不是按论文出现顺序讲。

第一步：从单步正则化更新得到线性化更新。 对任意任务 s ，正则化训练目标是一阶最优：

$$\nabla_w \mathcal{L}(w_s, Z_s + \eta_s) + H_s(w_s - w_{s-1}) = 0.$$

在干净单任务最优点 (w_s^*, Z_s) 附近展开梯度：为什么选这个点？有三个原因：

- w_s^* 是干净任务 s 的最优点，所以

$$\nabla_w \mathcal{L}(w_s^*, Z_s) = 0.$$

展开时常数项会消失，公式最简单。

- 我们想研究“投毒和正则化让模型偏离干净最优点多少”，所以自然以干净最优点为基准。
- Q_s 和 G_s 都是在干净数据上计算的局部几何量，表示没有攻击时任务本身的曲率和数据敏感性。

严格说，我们展开的是梯度函数

$$\Phi(w, Z) = \nabla_w \mathcal{L}(w, Z).$$

对两个变量 w 和 Z 做一阶 Taylor 展开：

$$\Phi(w_s, Z_s + \eta_s) \approx \Phi(w_s^*, Z_s) + \frac{\partial \Phi}{\partial w}(w_s^*, Z_s)(w_s - w_s^*) + \frac{\partial \Phi}{\partial Z}(w_s^*, Z_s) \text{vec}(\eta_s).$$

第一项为 0；第二项就是对 w 再求一次导，所以是 $Q_s(w_s - w_s^*)$ ；第三项是“数据变化如何改变参数梯度”，所以记作 $G_s \text{vec}(\eta_s)$ 。因此

$$\nabla_w \mathcal{L}(w_s, Z_s + \eta_s) \approx Q_s(w_s - w_s^*) + G_s \text{vec}(\eta_s),$$

其中

$$Q_s = \nabla_{ww}^2 \mathcal{L}(w_s^*, Z_s), \quad G_s = \nabla_{wZ}^2 \mathcal{L}(w_s^*, Z_s), \quad S_s = Q_s + H_s.$$

把它代回一阶最优性条件：

$$Q_s(w_s - w_s^*) + G_s \text{vec}(\eta_s) + H_s(w_s - w_{s-1}) \approx 0.$$

接下来为什么引入 w_a^* ？因为 T2T 后面既要比较 w_t 和 w_{t-1} ，又要比较 w_{t-1} 和 w_{t-2} 。统一写成“相对某个参照点 w_a^* 的偏移”，会让两次更新能放到同一种形式里。这个参照点不是新的假设，只是代数上选一个零点。选 $a = t - 1$ 可以看上一轮任务，选 $a = t$ 可以把当前任务和上一任务的差异显式写出来。

具体整理方式是把

$$w_s - w_s^* = (w_s - w_a^*) - (w_s^* - w_a^*), \quad w_s - w_{s-1} = (w_s - w_a^*) - (w_{s-1} - w_a^*)$$

代入上一行，把含 $w_s - w_a^*$ 的项放左边，就得到

$$S_s(w_s - w_a^*) \approx Q_s(w_s^* - w_a^*) + H_s(w_{s-1} - w_a^*) - G_s \text{vec}(\eta_s).$$

这里 w_a^* 是我们选来作参照的某个任务最优点。左乘 S_s^+ 得到

$$w_s - w_a^* \approx S_s^+ [Q_s(w_s^* - w_a^*) + H_s(w_{s-1} - w_a^*) - G_s \text{vec}(\eta_s)].$$

这就是“线性化更新”：原本复杂的训练结果 w_s ，被近似写成历史模型、任务差异、投毒扰动的线性组合。

第二步：为什么 A_t, B_t 是那样定义的。 现在我们关心两次更新：

$$w_t - w_{t-1}, \quad w_{t-1} - w_{t-2}.$$

先看上一轮更新。把上面的公式用于任务 $t - 1$ ，并把参照点取为 w_{t-1}^* ，得到

$$w_{t-1} - w_{t-2} \approx -S_{t-1}^+ Q_{t-1}(w_{t-2} - w_{t-1}^*) - S_{t-1}^+ G_{t-1} \text{vec}(\eta_{t-1}).$$

这里你可能会疑惑：上一轮更新里明明有正则化 H_{t-1} ，为什么公式里看不到显式的 H_{t-1} ？

原因是它没有消失，而是被吸收到

$$S_{t-1} = Q_{t-1} + H_{t-1}$$

里面了。看代数最清楚。上一轮的一阶条件近似为

$$Q_{t-1}(w_{t-1} - w_{t-1}^*) + G_{t-1} \text{vec}(\eta_{t-1}) + H_{t-1}(w_{t-1} - w_{t-2}) \approx 0.$$

令上一轮更新量

$$u = w_{t-1} - w_{t-2}.$$

则

$$w_{t-1} - w_{t-1}^* = u + (w_{t-2} - w_{t-1}^*).$$

代入：

$$Q_{t-1}[u + (w_{t-2} - w_{t-1}^*)] + G_{t-1} \text{vec}(\eta_{t-1}) + H_{t-1}u \approx 0.$$

把含 u 的项合并：

$$(Q_{t-1} + H_{t-1})u \approx -Q_{t-1}(w_{t-2} - w_{t-1}^*) - G_{t-1} \text{vec}(\eta_{t-1}).$$

所以

$$u = w_{t-1} - w_{t-2} \approx -S_{t-1}^+ Q_{t-1}(w_{t-2} - w_{t-1}^*) - S_{t-1}^+ G_{t-1} \text{vec}(\eta_{t-1}).$$

因此 H_{t-1} 在 $B_t = S_{t-1}^+ Q_{t-1}$ 里通过 S_{t-1}^+ 隐含存在，不是没了。

所以自然定义

$$B_t = S_{t-1}^+ Q_{t-1}.$$

B_t 的意义是：旧历史状态 w_{t-2} 如何进入上一轮更新。

再看当前更新。当前更新 $w_t - w_{t-1}$ 里会含有 w_{t-1} ，而 w_{t-1} 又由上一任务从 w_{t-2} 更新而来。把上一轮线性化结果继续代入当前轮，就会得到一条从 w_{t-2} 到 $w_t - w_{t-1}$ 的路径：

$$A_t = S_t^+ Q_t S_{t-1}^+ H_{t-1}.$$

A_t 的意义是：旧历史状态 w_{t-2} 经过上一轮正则化保留项 H_{t-1} ，再经过当前任务曲率 Q_t ，最后影响当前更新。

为什么 A_t 里显式出现 H_{t-1} ，而 B_t 没有？因为二者描述的路径不同：

- B_t 描述的是旧状态如何直接出现在上一轮更新 $w_{t-1} - w_{t-2}$ 里。这里 H_{t-1} 和 Q_{t-1} 一起组成左边的总曲率 S_{t-1} ，所以它藏在 S_{t-1}^+ 里。
- A_t 描述的是旧状态如何先影响 w_{t-1} ，再通过当前任务影响 $w_t - w_{t-1}$ 。旧状态传到 w_{t-1} 的那条“保留旧模型”的通道正是 H_{t-1} ，所以它在路径中显式出现。

因此 A_t, B_t 不是随便定义的，它们分别是“同一个历史状态在当前更新和上一更新中的传播矩阵”。

第三步：公式 17 和 18 的来源。 把上面的线性化代数完整代入，就得到两条关键关系：

$$\begin{aligned} w_t - w_{t-1} &\approx -A_t(w_{t-2} - w_t^*) + S_t^+ Q_t S_{t-1}^+ Q_{t-1}(w_t^* - w_{t-1}^*) \\ &\quad + S_t^+ Q_t S_{t-1}^+ G_{t-1} \text{vec}(\eta_{t-1}) - S_t^+ G_t \text{vec}(\eta_t), \\ w_{t-1} - w_{t-2} &\approx -B_t(w_{t-2} - w_{t-1}^*) - S_{t-1}^+ G_{t-1} \text{vec}(\eta_{t-1}). \end{aligned}$$

这两条就是 T2T 的原材料。它们告诉我们：两次更新里都带着旧历史状态 w_{t-2} ，只是一个被 A_t 处理，一个被 B_t 处理。

第四步：为什么要 $D_t^1 A_t = D_t^2 B_t$ 。 检测时要相减：

$$D_t^1(w_t - w_{t-1}) - D_t^2(w_{t-1} - w_{t-2}).$$

如果只看历史项，它们分别是

$$-D_t^1 A_t(w_{t-2} - \dots), \quad -D_t^2 B_t(w_{t-2} - \dots).$$

要让同一个旧历史状态在相减时抵消，必须让它们前面的线性变换一致：

$$D_t^1 A_t = D_t^2 B_t.$$

这就是 T2T 的核心约束。没有这个约束，检测分数仍然会混入很早以前的模型状态，无法只看最近两个任务。

第五步：为什么变成最小二乘投影问题。 满足 $D_t^1 A_t = D_t^2 B_t$ 的 D_t^1, D_t^2 可能有很多组。论文还希望它们尽量保留原更新里的信息，而不是随便把所有东西都压成 0。自然的选择是：让 D_t^1 尽量接近 A_t^+ ，让 D_t^2 尽量接近 B_t^+ 。这就得到

$$\min_{\bar{D}_t^1, \bar{D}_t^2} \|\bar{D}_t^1 - A_t^+\|_F^2 + \|\bar{D}_t^2 - B_t^+\|_F^2 \quad \text{s.t.} \quad \bar{D}_t^1 A_t = \bar{D}_t^2 B_t.$$

这不是为了形式复杂，而是在做一件很直观的事：既要抵消历史，又要尽量少扭曲两次更新。

第六步：为什么解里会出现 C_t ，以及为什么一个是减号一个是加号。 令

$$R_t = A_t^+ A_t - B_t^+ B_t.$$

如果直接取 $\bar{D}_t^1 = A_t^+$ 、 $\bar{D}_t^2 = B_t^+$ ，约束左边和右边相差 R_t 。所以要给二者加修正量，让一个往回减，另一个往前加：

$$\bar{D}_t^1 = A_t^+ - R_t K_t A_t^\top, \quad \bar{D}_t^2 = B_t^+ + R_t K_t B_t^\top.$$

这就是 D^1 中是减号、 D^2 中是加号的原因：两个修正朝相反方向移动，才能把中间差距补上。

把它们乘上 A_t, B_t ：

$$\bar{D}_t^1 A_t - \bar{D}_t^2 B_t = R_t - R_t K_t (A_t^\top A_t + B_t^\top B_t).$$

为了让这个差为 0，需要

$$K_t (A_t^\top A_t + B_t^\top B_t) \approx I$$

在相关子空间上成立。最小范数意义下的解就是

$$K_t = (A_t^\top A_t + B_t^\top B_t)^+.$$

论文为了少写一个 $R_t K_t$ ，把两者合并记作

$$C_t = (A_t^+ A_t - B_t^+ B_t)(A_t^\top A_t + B_t^\top B_t)^+$$

于是 $\bar{D}_t^1 = A_t^+ - C_t A_t^\top$ ， $\bar{D}_t^2 = B_t^+ + C_t B_t^\top$ 。它本质上就是“用最小二乘方式补齐 $A_t^+ A_t$ 和 $B_t^+ B_t$ 的差距”。

第七步：代回后为什么得到 E_t^1, E_t^2, E_t^3 。 把两条线性化更新代回检测差：

$$D_t^1(w_t - w_{t-1}) - D_t^2(w_{t-1} - w_{t-2}).$$

历史项因为 $D_t^1 A_t = D_t^2 B_t$ 消掉。剩下的项按来源分组：

- 和任务差异 $w_t^* - w_{t-1}^*$ 相乘的所有矩阵，合并叫 E_t^1 。
- 和上一任务攻击 $\text{vec}(\eta_{t-1})$ 相乘的所有矩阵，合并叫 E_t^2 。
- 和当前任务攻击 $\text{vec}(\eta_t)$ 相乘的所有矩阵，合并叫 E_t^3 。
- Taylor 展开的高阶残差，合并叫 $\mathcal{E}_t$ 。

于是得到

$$E_t^1(w_t^* - w_{t-1}^*) + E_t^2 \text{vec}(\eta_{t-1}) + E_t^3 \text{vec}(\eta_t) + \mathcal{E}_t.$$

这就是你问的公式 16 的来源：不是凭空来的，而是“历史项抵消后，把剩余项按来源重新命名”。

第八步：为什么良性任务时 $d_t^2 = \|E_t^2 e_{t-1} + E_t^3 e_t\|^2$ 。 在线性回归理论分析里，良性任务没有攻击，只有自然噪声：

$$\mathbf{n}_{t-1} = 0, \quad \mathbf{n}_t = 0.$$

这里 $\mathbf{n}_t$ 表示攻击额外加到标签上的扰动。良性时它为 0，但标签观测里仍然有自然噪声 $\mathbf{e}_t$ 。自然噪声和 label perturbation 一样都会通过标签通道影响梯度，所以在 T2T 分数里出现 $\mathbf{e}_{t-1}, \mathbf{e}_t$ 。共享参数模型下任务最优点的系统差异项被简化，检测分数主要变成

$$d_t^2 = \|E_t^2 \mathbf{e}_{t-1} + E_t^3 \mathbf{e}_t\|_2^2.$$

它的含义是：没有攻击时，检测分数只由最近两个任务的自然噪声造成。

第九步：交叉项期望为什么为 0。 展开平方：

$$d_t^2 = \|E_t^2 \mathbf{e}_{t-1}\|^2 + \|E_t^3 \mathbf{e}_t\|^2 + 2(E_t^2 \mathbf{e}_{t-1})^\top (E_t^3 \mathbf{e}_t).$$

最后一项叫交叉项。因为 e_{t-1} 和 e_t 来自不同任务，条件在特征矩阵上它们独立且均值为 0，所以

$$\mathbb{E}[\mathbf{e}_{t-1} \mathbf{e}_t^\top \mid X_{t-1}, X_t] = 0.$$

因此交叉项期望为 0。

噪声协方差假设

$$\mathbb{E}[\mathbf{e}_s \mathbf{e}_s^\top | X_s] = \sigma^2 I$$

表示：噪声平均为 0，每个方向的方差都是 σ^2 ，不同方向之间不相关。利用这个假设可得

$$\mathbb{E}[\|E_t^2 e_{t-1}\|^2 | X_{t-1}] = \sigma^2 \text{tr}((E_t^2)^\top E_t^2),$$

同理得到 E_t^3 那一项。两项相加就是公式 19。

第十步：为什么用 Markov 不等式，以及公式 20 怎么来。 我们想给良性任务的检测分数找一个阈值，保证良性任务大概率不会被误报。 d_t^2 是非负随机变量，所以最直接可用 Markov 不等式：

$$\Pr(X > a) \leq \frac{\mathbb{E}[X]}{a}.$$

令 $X = d_t^2$ 。希望单个时刻误报概率不超过 ϵ/T ，就取

$$a = \frac{T}{\epsilon} \mathbb{E}[d_t^2].$$

也就是

$$\theta_t^2 = \frac{T}{\epsilon} \sigma^2 \left[\text{tr}((E_t^2)^\top E_t^2) + \text{tr}((E_t^3)^\top E_t^3) \right].$$

开平方就得到公式 20。再对所有 t 用 union bound，就能保证整个训练过程中良性任务同时不过阈值的概率至少为 $1 - \epsilon$ 。

第十一步：sub-Gaussian 和 Hanson-Wright 是什么。 Markov 不等式很通用，但很松。若噪声是 sub-Gaussian，说明它的尾部像高斯分布一样下降很快，不容易出现极端大值。直观上：

$$\Pr(|X| > u)$$

会随 u 增大快速下降。

Hanson-Wright 不等式专门控制 sub-Gaussian 随机向量的二次型：

$$\xi^\top A \xi.$$

而这里

$$d_t^2 = \xi_t^\top R_t^\top R_t \xi_t$$

正是二次型。因此若噪声 sub-Gaussian，就可以用 Hanson-Wright 给出比 Markov 更紧的阈值，通常从 T/ϵ 量级改善到 $\log(T/\epsilon)$ 量级。

第十二步：正则化矩阵公式 21 从哪里来。 T2T 最终收敛证明选用

$$H_t = \frac{1}{n_t} \left(\frac{\sigma^2}{W} I + \sum_{s=1}^{t-1} X_s^\top X_s \right).$$

这个选择可以理解成“历史数据信息的累计”。 $\sum_{s=1}^{t-1} X_s^\top X_s$ 是过去任务给出的总曲率/信息量； σ^2/W 像一个初始先验强度，避免一开始矩阵不可逆；前面的 $1/n_t$ 是为了和当前任务损失里的 $X_t^\top X_t/n_t$ 尺度一致。

这个 H_t 的好处是递推会望远镜式简化，最终 $w_T - w^*$ 可以写成所有任务噪声和攻击的加权和，方便证明收敛。

第十三步：式 22 从哪里来。 在线性回归中，带标签扰动的目标是

$$\frac{1}{2n_t} \|X_t w - (X_t w^* + \mathbf{e}_t + \mathbf{n}_t)\|^2 + \frac{1}{2} \|w - w_{t-1}\|_{H_t}^2.$$

对 w 求梯度并令 0:

$$\frac{X_t^\top}{n_t} [X_t(w - w^*) - (\mathbf{e}_t + \mathbf{n}_t)] + H_t(w - w_{t-1}) = 0.$$

把 $w = w_t$ ，并把含 $w_t - w^*$ 的项放左边：

$$\left(\frac{X_t^\top X_t}{n_t} + H_t \right) (w_t - w^*) = \frac{X_t^\top (\mathbf{e}_t + \mathbf{n}_t)}{n_t} + H_t(w_{t-1} - w^*).$$

左乘逆矩阵，就得到式 22：

$$w_t - w^* = \left(\frac{X_t^\top X_t}{n_t} + H_t \right)^{-1} \left[\frac{X_t^\top (\mathbf{e}_t + \mathbf{n}_t)}{n_t} + H_t(w_{t-1} - w^*) \right].$$

这说明最终递推仍然来自同一个原则：正则化训练目标求梯度等于 0。

6.6 检测阈值：Lemma 4.3

在线性回归假设下，如果任务 $t-1$ 和 t 都是良性的，那么

$$d_t^2 = \|E_t^2 \mathbf{e}_{t-1} + E_t^3 \mathbf{e}_t\|_2^2.$$

噪声独立、零均值，且

$$\mathbb{E}[\mathbf{e}_s \mathbf{e}_s^\top | X_s] = \sigma^2 I.$$

因此交叉项期望为 0，

$$\mathbb{E}[d_t^2 | X_{t-1}, X_t] = \sigma^2 \text{tr}((E_t^2)^\top E_t^2) + \sigma^2 \text{tr}((E_t^3)^\top E_t^3). \quad (19)$$

用 Markov 不等式：

$$\Pr(d_t^2 > \theta_t^2) \leq \epsilon/T,$$

取

$$\theta_t = \sqrt{\frac{\sigma^2 T}{\epsilon} [\text{tr}((E_t^2)^\top E_t^2) + \text{tr}((E_t^3)^\top E_t^3)]}. \quad (20)$$

再对所有 t 用 union bound，得到同时成立概率至少 $1 - \epsilon$ 。

如果噪声是 sub-Gaussian，可以用 Hanson-Wright 不等式替代 Markov 不等式，阈值会从粗糙的 T/ϵ 型改善成对数型 $\log(T/\epsilon)$ 。

6.7 Theorem 4.4：最终误差界

论文选用正则化矩阵

$$H_t = \frac{1}{n_t} \left(\frac{\sigma^2}{W} I + \sum_{s=1}^{t-1} \mathbf{X}_s^\top \mathbf{X}_s \right). \quad (21)$$

把攻击写成标签扰动 $\mathbf{n}_t$ ，其中未攻击时 $\mathbf{n}_t = 0$ 。线性回归递推为

$$\mathbf{w}_t - \mathbf{w}^* = \left(\frac{\mathbf{X}_t^\top \mathbf{X}_t}{n_t} + H_t \right)^{-1} \left[\frac{\mathbf{X}_t^\top (\mathbf{e}_t + \mathbf{n}_t)}{n_t} + H_t (\mathbf{w}_{t-1} - \mathbf{w}^*) \right]. \quad (22)$$

代入 (21) 并展开递推，有

$$\mathbf{w}_T - \mathbf{w}^* = \tilde{\mathbf{X}}_{T+1}^{-1} \left[\sum_{s=1}^T \mathbf{X}_s^\top (\mathbf{e}_s + \mathbf{n}_s) + \frac{\sigma^2}{W} (\mathbf{w}_0 - \mathbf{w}^*) \right], \quad (23)$$

其中

$$\tilde{\mathbf{X}}_{T+1} = \frac{\sigma^2}{W} I + \sum_{s=1}^T \mathbf{X}_s^\top \mathbf{X}_s.$$

把任务分成良性任务和漏检攻击任务 $\mathcal{K} = \{t_1, \dots, t_K\}$ 。检测到的攻击会被回滚丢弃，不进入最终递推；真正需要控制的是漏检攻击。由 T2T 阈值可推出，任何漏检攻击必须满足

$$\left\| \left(\frac{\mathbf{X}_t^\top \mathbf{X}_t}{n_t} \right)^+ \frac{\mathbf{X}_t^\top}{n_t} (\mathbf{n}_t + \mathbf{e}_t) \right\|_2^2 \leq \frac{\sigma^2 T}{\epsilon} \text{tr}(\mathbf{X}_t^\top \mathbf{X}_t)^+. \quad (24)$$

直观解释：如果攻击超过这个尺度，在某个最坏未来任务对齐下，下一次 T2T 分数会超过阈值，攻击会被检测并回滚。

由 (23)，

$$\begin{aligned} \mathbb{E} \|\mathbf{w}_T - \mathbf{w}^*\|^2 &\leq \sigma^2 \text{tr}(\tilde{\mathbf{X}}_{T+1}^{-1}) \\ &\quad + K \sum_{k=1}^K \left\| \tilde{\mathbf{X}}_{T+1}^{-1} (\mathbf{X}_{t_k}^\top \mathbf{X}_{t_k}) \right\|_2^2 \frac{\sigma^2 T}{\epsilon} \text{tr}(\mathbf{X}_{t_k}^\top \mathbf{X}_{t_k})^+. \end{aligned} \quad (25)$$

第一项是良性噪声误差；第二项是漏检攻击误差。

若所有任务 informative，即每个参数方向都能在 T 个任务中得到线性数量的信息，则 $\tilde{\mathbf{X}}_{T+1}$ 的特征值按 $\Theta(T)$ 增长。于是

$$\text{tr}(\tilde{\mathbf{X}}_{T+1}^{-1}) = O(1/T), \quad \left\| \tilde{\mathbf{X}}_{T+1}^{-1} (\mathbf{X}_{t_k}^\top \mathbf{X}_{t_k}) \right\|_2^2 = O(1/T^2).$$

代入 (25) 得

$$\mathcal{R}(w_T) = O\left(\frac{K^2}{\epsilon T}\right).$$

当 $K = O(1)$ 时，最终误差收敛到 0。

7 频繁有界零均值攻击：鲁棒特征防御

7.1 先不看公式：第二种防御的整体逻辑

T2T 适合“攻击次数少但每次可能很强”的情况。它的策略像安检：发现可疑任务就丢掉或回滚。

但如果攻击很频繁，几乎每个任务都有一点污染，安检式防御就不适合了。因为你不能把大部分任务都丢掉，否则模型没有数据可学。所以第二种防御换了思路：不再主要判断“哪个任务坏了”，而是让模型在训练时自动降低对脆弱特征方向的敏感性。

可以把模型参数空间想象成很多方向：

$$u_1, u_2, \dots, u_p.$$

有些方向数据很充分、噪声影响小；有些方向数据很弱、攻击稍微一推就会造成大误差。攻击者最喜欢打后者。

正则化矩阵 H_t 在这里就像一组方向刹车：

- 某个方向的正则化强，模型就不容易沿这个方向被当前任务数据拉走。
- 某个方向的正则化弱，模型就更愿意吸收当前任务在这个方向的信息。

鲁棒特征防御要做的是：给每个方向选择合适的刹车强度，让攻击者即使知道模型，也很难找到一个特别脆弱的方向集中攻击。

这一节的符号可以这样理解：

- u_j ：第 j 个特征方向。
- γ_j^t ：任务 t 在方向 u_j 上提供了多少数据信息。越大，说明这个方向数据越有力。
- λ_j^t ：防御者在方向 u_j 上设置的正则化强度，也就是刹车强度。
- $\mathcal{R}_j^t$ ：模型在方向 u_j 上还剩多少误差。
- M ：攻击者总预算。

为什么要对角化？如果不对角化，各方向混在一起，一个方向的更新会影响另一个方向，分析非常复杂。对角化的目的不是炫技，而是把一个高维矩阵问题拆成许多一维问题：

第1个方向怎么设刹车，第2个方向怎么设刹车，...

这样才能解释“攻击者会打哪个方向”和“防御者应该保护哪些方向”。

为什么会有 **protected set**？因为攻击者预算有限，不会平均打所有方向，而会集中攻击最敏感的一组方向。防御者识别出这组方向后，把它们作为 **protected set**，专门调整这些方向的正则化强度，避免最坏方向单独决定总误差。

7.2 为什么不能继续靠检测

如果几乎每个任务都被攻击，T2T 检测即使有效，也会不断丢任务，模型无法学习。此时要换思路：不再拒绝任务，而是调整正则化矩阵 H_t ，让模型对攻击最敏感的方向变得不敏感。

7.3 线性模型中的 **minimax** 递推

在向量化线性回归下，带 **non-shifted** 攻击的递推是

$$w_t - w_\star = S_t^{-1} \left[\frac{X_t^\top (\varepsilon_t + \tilde{\eta}_t)}{n_t} + H_t (w_{t-1} - w_\star) \right], \quad S_t = \frac{X_t^\top X_t}{n_t} + H_t. \quad (26)$$

因为 $\tilde{\eta}_t$ 是零均值并与历史误差条件不相关，

$$\mathbb{E}[w_t - w_\star] = S_t^{-1} H_t \mathbb{E}[w_{t-1} - w_\star], \quad (27)$$

$$\begin{aligned} \text{Cov}(w_t - w_*) &= S_t^{-1} \frac{X_t^\top}{n_t} (\text{Cov}(\tilde{\eta}_t) + \sigma^2 I) \frac{X_t}{n_t} S_t^{-1} \\ &\quad + S_t^{-1} H_t \text{Cov}(w_{t-1} - w_*) H_t^\top S_t^{-1}. \end{aligned} \quad (28)$$

于是防御者在每轮求解

$$\begin{aligned} \min_{H_t} \max_{\text{Cov}(\tilde{\eta}_t) \succeq 0} \quad & \|S_t^{-1} H_t \mathbb{E}[w_{t-1} - w_*]\|_2^2 \\ & + \text{tr} \left(S_t^{-1} \frac{X_t^\top}{n_t} (\text{Cov}(\tilde{\eta}_t) + \sigma^2 I) \frac{X_t}{n_t} S_t^{-1} \right) \\ & + \text{tr} \left(S_t^{-1} H_t \text{Cov}(w_{t-1} - w_*) H_t^\top S_t^{-1} \right) \\ \text{s.t.} \quad & \text{tr}(\text{Cov}(\tilde{\eta}_t)) \leq M. \end{aligned} \quad (29)$$

7.4 对角化假设与每个方向的风险

假设所有任务 Hessian 两两可交换：

$$X_s^\top X_s X_t^\top X_t = X_t^\top X_t X_s^\top X_s.$$

则它们可以被同一个正交矩阵 $U = [u_1, \dots, u_p]$ 同时对角化：

$$\frac{X_t^\top X_t}{n_t} = U \Gamma_t U^\top, \quad \Gamma_t = \text{diag}(\gamma_1^t, \dots, \gamma_p^t).$$

只需考虑

$$H_t = U \Lambda_t U^\top, \quad \Lambda_t = \text{diag}(\lambda_1^t, \dots, \lambda_p^t).$$

定义第 j 个方向的误差贡献

$$\mathcal{R}_j^t = \mathbb{E}[(u_j^\top (w_t - w_*))^2], \quad \mathcal{R}(w_t) = \sum_{j=1}^p \mathcal{R}_j^t.$$

投影到 u_j 方向，若 $\gamma_j^t > 0$ ，有

$$u_j^\top (w_t - w_*) = \frac{1}{\lambda_j^t + \gamma_j^t} \left[\frac{\sqrt{\gamma_j^t}}{\sqrt{n_t}} (v_j^t)^\top (\varepsilon_t + \tilde{\eta}_t) + \lambda_j^t u_j^\top (w_{t-1} - w_*) \right], \quad (30)$$

其中 $v_j^t = X_t u_j / \sqrt{n_t \gamma_j^t}$ 且 $\|v_j^t\| = 1$ 。由零均值和不相关性，

$$\mathcal{R}_j^t = \left(\frac{\lambda_j^t}{\lambda_j^t + \gamma_j^t} \right)^2 \mathcal{R}_j^{t-1} + \frac{\gamma_j^t (\sigma^2 + (v_j^t)^\top \text{Cov}(\tilde{\eta}_t) v_j^t)}{n_t (\lambda_j^t + \gamma_j^t)^2}. \quad (31)$$

固定 λ_j^t 后，攻击者的目标对 $\text{Cov}(\tilde{\eta}_t)$ 是线性的。所以最优攻击把全部预算 M 放到最敏感方向：

$$j^* \in \arg \max_j \frac{\gamma_j^t}{n_t (\lambda_j^t + \gamma_j^t)^2}, \quad \text{Cov}(\tilde{\eta}_t) = M v_{j^*}^t (v_{j^*}^t)^\top.$$

于是防御问题等价于

$$\min_{\lambda_1^t, \dots, \lambda_p^t} \max_j \frac{M \gamma_j^t}{n_t (\lambda_j^t + \gamma_j^t)^2} + \sum_{j=1}^p \left[\left(\frac{\lambda_j^t}{\lambda_j^t + \gamma_j^t} \right)^2 \mathcal{R}_j^{t-1} + \frac{\gamma_j^t \sigma^2}{n_t (\lambda_j^t + \gamma_j^t)^2} \right]. \quad (32)$$

7.5 Proposition 5.2: 最优正则化的水位结构

令

$$\tilde{\gamma}_j^t = \gamma_j^t n_t, \quad \mathcal{I}_t^+ = \{j : \tilde{\gamma}_j^t > 0, \mathcal{R}_j^{t-1} > 0\}.$$

对 $j \in \mathcal{I}_t^+$, 定义

$$b_j^t = \frac{\mathcal{R}_j^{t-1} \tilde{\gamma}_j^t + \sigma^2}{\mathcal{R}_j^{t-1} \sqrt{\tilde{\gamma}_j^t}}.$$

按 b_j^t 从小到大排序。再定义

$$A_j^t = \frac{M + j\sigma^2 + \sum_{k=1}^j \mathcal{R}_k^{t-1} \tilde{\gamma}_k^t}{\sum_{k=1}^j \mathcal{R}_k^{t-1} \sqrt{\tilde{\gamma}_k^t}}.$$

令 j_t 是满足

$$A_{j_t}^t > b_{j_t}^t$$

的最大 j 。那么最优防御为

$$\lambda_j^t = \begin{cases} \frac{\sigma^2}{n_t \mathcal{R}_j^{t-1}}, & j \in \mathcal{I}_t^+, j > j_t, \\ A_{j_t}^t \sqrt{\frac{\gamma_j^t}{n_t}} - \gamma_j^t, & j \in \mathcal{I}_t^+, j \leq j_t, \\ +\infty, & \gamma_j^t > 0, \mathcal{R}_j^{t-1} = 0, \\ \text{任意正数}, & \gamma_j^t = 0. \end{cases} \quad (33)$$

7.6 Proposition 5.2 的证明

证明从变量替换开始:

$$c_j^t = \frac{\lambda_j^t}{\lambda_j^t + \gamma_j^t}.$$

这表示第 j 个方向保留旧模型的比例; $1 - c_j^t$ 表示当前任务数据进入模型的比例。

忽略退化方向后, 问题变成

$$\begin{aligned} \min_{\{c_j^t\}, z} \quad & \sum_{j \in \mathcal{I}_t^+} \left[(c_j^t)^2 \mathcal{R}_j^{t-1} + \frac{(1 - c_j^t)^2 \sigma^2}{n_t \gamma_j^t} \right] + zM \\ \text{s.t.} \quad & z \geq \frac{(1 - c_j^t)^2}{\gamma_j^t n_t}, \quad j \in \mathcal{I}_t^+. \end{aligned} \quad (34)$$

这里 z 代表最大攻击敏感度。

对约束引入乘子 $\chi_j \geq 0$ 。KKT 条件给出

$$\sum_{j \in \mathcal{I}_t^+} \chi_j = M$$

以及

$$c_j^t = \frac{(\sigma^2 + \chi_j)/(n_t \gamma_j^t)}{\mathcal{R}_j^{t-1} + (\sigma^2 + \chi_j)/(n_t \gamma_j^t)}. \quad (35)$$

若 $\chi_j > 0$ ，说明方向 j 的最大敏感度约束是活跃的：

$$z = \frac{(1 - c_j^t)^2}{\gamma_j^t n_t}.$$

把 (35) 代入可得

$$\chi_j = \frac{\mathcal{R}_j^{t-1} \sqrt{\gamma_j^t n_t}}{\sqrt{z}} - \sigma^2 - \gamma_j^t n_t \mathcal{R}_j^{t-1}. \quad (36)$$

设活跃集合为 $J_t = \{j : \chi_j > 0\}$ 。由 $\sum \chi_j = M$ 得

$$\frac{1}{\sqrt{z}} = \frac{M + |J_t| \sigma^2 + \sum_{j \in J_t} \gamma_j^t n_t \mathcal{R}_j^{t-1}}{\sum_{j \in J_t} \mathcal{R}_j^{t-1} \sqrt{\gamma_j^t n_t}}.$$

这就是 A_j^t 的来源。

接下来要确定 J_t 。令

$$a_j = \mathcal{R}_j^{t-1} \sqrt{\gamma_j^t n_t}, \quad b_j = \frac{\gamma_j^t n_t \mathcal{R}_j^{t-1} + \sigma^2}{\mathcal{R}_j^{t-1} \sqrt{\gamma_j^t n_t}}.$$

对任意候选活跃集合 J ，KKT 条件给出

$$\chi_k = a_k(A_J - b_k).$$

因此：

$$k \in J \Rightarrow b_k < A_J, \quad k \notin J \Rightarrow b_k \geq A_J.$$

所以活跃集合必须是按 b_j 排序后的一个前缀。最大满足 $A_j^t > b_j^t$ 的 j 就是前缀长度 j_t 。

最后由

$$\lambda_j^t = \frac{c_j^t \gamma_j^t}{1 - c_j^t}$$

还原回 λ_j^t ，得到 (33)。

说明 7.1. b_j^t 越小，方向 j 越容易进入 protected set。直观上，这些方向要么当前特征信息弱，要么历史误差大，要么噪声相对影响强，因此更容易被攻击者利用。

7.7 Theorem 5.3：为什么鲁棒特征防御更快

定理考虑一个特殊平稳情形：protected set 长期固定为

$$\{1, \dots, j_T\}.$$

对 protected directions 定义总误差

$$\Phi_t = \sum_{j=1}^{j_T} \mathcal{R}_j^t, \quad f_j^t = \frac{\mathcal{R}_j^t}{\Phi_t}.$$

假设 $f_j^t \rightarrow f_j$ ，且 $\tilde{\gamma}_j^t \rightarrow \tilde{\gamma}_j^T$ 。

在 **protected directions** 上, KKT 条件让攻击敏感度相等:

$$\frac{(1 - c_j^t)^2}{\tilde{\gamma}_j^t} = z_t, \quad j = 1, \dots, j_T.$$

因此

$$c_j^t = 1 - \sqrt{z_t \tilde{\gamma}_j^t}.$$

由 KKT 水位公式:

$$\sqrt{z_t} = \frac{\sum_{i=1}^{j_T} \sqrt{\tilde{\gamma}_i^t} \mathcal{R}_i^{t-1}}{M + j_T \sigma^2 + \sum_{i=1}^{j_T} \tilde{\gamma}_i^t \mathcal{R}_i^{t-1}}.$$

把 **protected directions** 的风险加总, 得到核心递推:

$$\Phi_t = \Phi_{t-1} - \frac{\left(\sum_{j=1}^{j_T} \sqrt{\tilde{\gamma}_j^t} \mathcal{R}_j^{t-1} \right)^2}{M + j_T \sigma^2 + \sum_{j=1}^{j_T} \tilde{\gamma}_j^t \mathcal{R}_j^{t-1}}. \quad (37)$$

把 $\mathcal{R}_j^{t-1} = f_j^{t-1} \Phi_{t-1}$ 代入, 并取倒数, 可写成

$$\frac{1}{\Phi_t} - \frac{1}{\Phi_{t-1}} = \frac{\left(\sum_{j=1}^{j_T} f_j^{t-1} \sqrt{\tilde{\gamma}_j^t} \right)^2}{M + j_T \sigma^2 + \Phi_{t-1} \left[\sum_{j=1}^{j_T} f_j^{t-1} \tilde{\gamma}_j^t - \left(\sum_{j=1}^{j_T} f_j^{t-1} \sqrt{\tilde{\gamma}_j^t} \right)^2 \right]}. \quad (38)$$

Cauchy 不等式保证中括号非负, 因此 Φ_t 单调下降。在平稳假设下, 分子收敛到

$$C_\star = \left(\sum_{j=1}^{j_T} f_j \sqrt{\tilde{\gamma}_j^T} \right)^2 > 0,$$

而 $\Phi_t \rightarrow 0$, 所以分母最终趋于 $M + j_T \sigma^2$ 。于是

$$\frac{1}{\Phi_t} - \frac{1}{\Phi_{t-1}} \rightarrow \frac{C_\star}{M + j_T \sigma^2}.$$

累加并用 Cesaro 平均得到

$$\Phi_T \sim \frac{M + j_T \sigma^2}{T \left(\sum_{j=1}^{j_T} f_j \sqrt{\tilde{\gamma}_j^T} \right)^2}.$$

对非 **protected directions**, 攻击者不投预算, 递推退化为

$$\mathcal{R}_j^t = \frac{\sigma^2 \mathcal{R}_j^{t-1}}{\sigma^2 + \tilde{\gamma}_j^t \mathcal{R}_j^{t-1}}.$$

取倒数:

$$\frac{1}{\mathcal{R}_j^t} = \frac{1}{\mathcal{R}_j^{t-1}} + \frac{\tilde{\gamma}_j^t}{\sigma^2}.$$

展开得

$$\mathcal{R}_j^T \leq \frac{\sigma^2}{\sigma^2/W + \sum_{t=1}^T \tilde{\gamma}_j^t}.$$

因此鲁棒防御的总误差为

$$\mathcal{R}(w_T) \lesssim \frac{M + j_T \sigma^2}{T \left(\sum_{j=1}^{j_T} f_j \sqrt{\tilde{\gamma}_j^T} \right)^2} + \sum_{j=j_T+1}^p \frac{\sigma^2}{\sigma^2/W + \sum_{\tau=1}^T \tilde{\gamma}_j^\tau}. \quad (39)$$

7.8 和普通正则化 / EWC 型基线的比较

基线使用

$$H_t = \frac{1}{n_t} \left(\frac{\sigma^2}{W} I + \sum_{\tau=1}^{t-1} X_{\tau}^{\top} X_{\tau} \right).$$

在方向 j 上, 最终噪声权重约为

$$\frac{\sqrt{\tilde{\gamma}_j^t}}{\sigma^2/W + \sum_{\tau=1}^T \tilde{\gamma}_j^{\tau}}.$$

攻击者每轮把预算投到最坏方向, 攻击项变成

$$M \max_j \frac{\sum_{t=1}^T \tilde{\gamma}_j^t}{\left(\sigma^2/W + \sum_{t=1}^T \tilde{\gamma}_j^t \right)^2}.$$

平稳时

$$\sum_{t=1}^T \tilde{\gamma}_j^t \sim T \tilde{\gamma}_j^T,$$

于是基线攻击项近似

$$\max_j \frac{M}{T \tilde{\gamma}_j^T}.$$

这意味着一个小 $\tilde{\gamma}_j^T$ 的脆弱方向就可能主导误差。鲁棒特征防御则用 `protected set` 把敏感度平均化, 攻击项变为

$$\frac{M + j_T \sigma^2}{T \left(\sum_{j=1}^{j_T} f_j \sqrt{\tilde{\gamma}_j^T} \right)^2},$$

不再完全由单个最坏方向决定。

8 实验部分怎么读

实验不是证明的核心, 但它验证了两个理论直觉。

- 对 `infrequent shifted attacks`, T2T 检测分数 d_t 在攻击任务附近出现峰值。即使测试准确率看起来没明显变化, 微观更新分数仍能暴露攻击。
- 对 `frequent bounded non-shifted attacks`, iCaRL 这类 `replay/memorization` 方法在频繁攻击下可能更脆弱, 因为它没有显式正则化矩阵来降低敏感方向。鲁棒特征防御比普通 EWC 型正则化收敛更快。

9 读公式的路线图

如果从头读论文很吃力, 可以按以下顺序理解。

1. 先看 (2)。所有防御都只是在设计 H_t 或通过检测让 $H_t \rightarrow \infty$ 。
2. 再看 (4)。它告诉你攻击者为什么打最大奇异方向。
3. 用一维递推 (9) 理解 Theorem 3.1。这个定理不需要复杂矩阵。

4. 用等式 $D_t^1 A_t = D_t^2 B_t$ 理解 T2T。它解释了为什么 d_t 能消去历史。
5. 用 (23) 理解 T2T 的收敛界。最终模型就是所有噪声与攻击的加权和。
6. 用 (31) 理解鲁棒特征防御。每个特征方向有一个独立风险递推。
7. 用 KKT 条件理解 (33)。protected set 是一个排序后的前缀集合。
8. 最后看 (38)。Theorem 5.3 的 $O(1/T)$ 来自倒数递推。

10 这篇论文的假设与局限

- 最完整的证明建立在线性回归和平方损失上。论文用 NTK 和预训练线性头解释为什么这对非线性模型有启发，但严格结论仍然依赖线性化结构。
- T2T 防御需要维护最近几个模型、正则化矩阵和 Hessian 信息。高维神经网络中必须用 Hessian 近似。
- Theorem 4.4 中 informative tasks 假设很关键。若某些参数方向长期没有数据信息，即使没有攻击也不能保证收敛。
- Theorem 5.3 的闭式收敛率依赖 protected set 平稳、Hessian 可同时对角化等假设。这些假设主要用于给出可解释的理论形式。
- 攻击预算 M 在鲁棒特征防御中需要被知道或至少有上界。若上界过松，正则化可能过保守。

11 一句话总结

这篇论文的核心观点是：连续学习中的投毒攻击不是普通噪声，而是沿时间累积的策略性偏置。频繁均值偏移或巨大方差攻击会打破任何正则化 CL 的收敛保证；少量强攻击可以通过 task-to-task 投影检测并回滚；频繁有界零均值攻击则需要在 Hessian 特征方向上做 minimax 正则化，把攻击者最想利用的敏感方向压平。

参考文献

- [1] Yiting Hu and Lingjie Duan. *Theory of Continual Learning Against Data Poisoning Attacks*. arXiv:2606.29841, 2026.