

BrainWash 补充问题 2：Model Inversion 细节与 EEG 先验

2024 CVPR BrainWash

1 MI 时到底需要知道什么

在 BrainWash 的 Model Inversion (MI) 阶段，攻击者至少需要：

- 已训练好的 victim model，尤其是旧任务后的 backbone 参数 $\theta_{1:T-1}^*$ ；
- 第 t 个旧任务 head 的参数 ψ_t^* ；
- 第 t 个 head 的输出维度 K_t ，也就是该任务类别数；
- 能够对输入 x 反向传播梯度。

论文默认是 white-box 或近似 white-box 的设定：攻击者能访问模型结构和参数，因此可以固定模型参数，然后对输入 x 做梯度优化。如果只能黑盒查询输出概率，也存在其他 confidence-based MI 方法，但 BrainWash 本文采用的是类似 DeepInversion 的梯度式输入优化。

2 目标标签和输入是不是都随机给

是，但要分清“随机初始化”和“最终合成结果”。

对旧任务 t ，攻击者先随机采样一批目标 one-hot 标签：

$$\{\hat{y}_t^i\}_{i=1}^M, \quad \hat{y}_t^i \in \mathcal{Y}_t = \{1, \dots, K_t\}.$$

例如如果第 t 个 head 有 $K_t = 10$ 个 logits，攻击者可以随机指定第 i 个合成样本的目标类别为第 7 类：

$$\hat{y}_t^i = [0, 0, 0, 0, 0, 0, 1, 0, 0, 0]^\top.$$

输入 x_i 通常也从随机噪声初始化：

$$x_i^{(0)} \sim \mathcal{N}(0, I) \quad \text{或} \quad x_i^{(0)} \sim \mathcal{U}(0, 1).$$

但最终的 $\hat{x}_t^i$ 不是随机噪声。它是经过梯度下降优化后的输入：

$$\hat{x}_t^i = x_i^{(S)},$$

其中 S 是 MI 优化步数。

3 输入优化是在真实运行的模型上做的吗

这里的“真实运行的模型”应理解为：攻击者拿到 victim 已经训练好的模型副本，在这个模型上做前向传播和反向传播。训练好的模型参数保持不变，优化变量只有输入。

第 s 步可以写成：

$$x_i^{(s+1)} = \Pi_{\mathcal{X}} \left[x_i^{(s)} - \gamma \nabla_{x_i} \mathcal{J}_{\text{MI}}(x_i^{(s)}, \hat{y}_t^i; \theta_{1:T-1}^*, \psi_t^*) \right],$$

其中：

- γ 是 MI 的输入优化步长;
- $\Pi_{\mathcal{X}}$ 是把输入投影回合法输入范围, 例如图像像素范围 $[0, 1]$;
- $\theta_{1:T-1}^*, \psi_t^*$ 固定不更新;
- 更新的是 x_i , 不是模型参数。

MI 的完整优化目标可以写成:

$$\mathcal{J}_{\text{MI}} = \mathcal{L}(x_i, \hat{y}_t^i, \theta_{1:T-1}^*, \psi_t^*) + R_{\text{prior}}(x_i) + \alpha_f R_{\text{feat}}(\{x_i\}_{i=1}^M, \theta_{1:T-1}^*).$$

所以, MI 不是在继续训练 victim model。它是在一个 frozen victim model 上反向优化输入, 让输入触发模型内部已经学到的旧任务类别模式。

4 是不是把伪标签或污染错误标签绑定到输入上

严格地说, 不是“把污染的错误标签绑定到输入上”。在 BrainWash 中需要区分两类数据:

1. MI 合成的旧任务代理数据:

$$\hat{D}_t = \{(\hat{x}_t^i, \hat{y}_t^i)\}_{i=1}^M.$$

这里的 $\hat{y}_t^i$ 是攻击者指定的目标标签, 用于让 frozen model 把合成输入判成该类。它是 proxy label, 不是 victim 训练时接收的 poisoned wrong label。

2. 真正投毒给 victim 的当前任务数据:

$$\tilde{D}_T = \{(x_T^i + \delta^i, y_T^i)\}_{i=1}^{N_T}.$$

这里标签 y_T^i 仍然是当前任务的原始标签。BrainWash 的主攻击是 input poisoning, 即添加输入扰动 δ^i , 不是 label-flipping attack。

MI 阶段的 $\hat{y}_t^i$ 更准确地说是“目标类标签”或“代理标签”。它的作用是告诉优化器: 请找到一个输入 $\hat{x}_t^i$, 使得旧任务 head h_t 认为它属于这个类别。

5 合成样本要让某个 head 判成特定 class 还是随机 class

对每个旧任务 t , BrainWash 会针对第 t 个 head 生成代理数据。也就是说, 合成样本需要被对应旧任务 head h_t 判成目标类别。

目标类别本身是随机采样的:

$$\hat{y}_t^i \sim \text{Uniform}(\mathcal{Y}_t).$$

给定这个随机采样出来的目标类别后, 优化目标就是特定的:

$$\hat{x}_t^i \approx \arg \min_{x_i} \text{CE}(\text{softmax}(h_t(f(x_i; \theta_{1:T-1}^*); \psi_t^*)), \hat{y}_t^i) + \text{regularization}.$$

因此答案是: 类别在生成前随机采样; 一旦采样完成, 该样本就要被优化成让指定 head 判为这个特定 class。不是让任意 head 随便判成任意 class。

6 攻击者是否利用已知结构和参数优化输入

是。BrainWash 的 MI 过程依赖已训练模型的结构和参数。攻击者利用:

- backbone $f(\cdot; \theta_{1:T-1}^*)$ 的梯度;
- 旧任务 head $h_t(\cdot; \psi_t^*)$ 的梯度;
- BatchNorm running mean/variance 等模型内部统计;

- 第 t 个 head 的 logits 维度 K_t 。

但是这一步的目标不是修改模型，而是从模型中“反演”出能代表旧任务类别的代理输入。

7 图像先验与 EEG 先验

图像领域常用自然图像先验，例如 total variation、像素范数、BatchNorm 特征统计：

$$R_{\text{prior}}(x) = \alpha_{\text{TV}} R_{\text{TV}}(x) + \alpha_{\ell_2} R_{\ell_2}(x).$$

EEG 领域没有一个像自然图像先验那样通用、标准化的先验，但可以设计领域相关的约束。常见方向如下。

7.1 幅值范围与归一化先验

EEG 信号有合理的幅值范围。如果模型输入是归一化后的 EEG，可以约束：

$$x \in [x_{\min}, x_{\max}] \quad \text{或} \quad \|x\|_2^2 \leq c.$$

这类似图像中的像素范围和 ℓ_2 范数约束。

7.2 时间平滑先验

EEG 是连续时间信号，过强的相邻采样点跳变通常不自然。可以使用一阶或二阶差分正则：

$$R_{\text{time}}(x) = \sum_{c=1}^C \sum_{\tau=2}^L (x_{c,\tau} - x_{c,\tau-1})^2.$$

其中 C 是通道数， L 是时间长度。

7.3 频带先验

EEG 常关注特定频段，例如 delta、theta、alpha、beta、gamma。可以惩罚不合理频段的能量：

$$R_{\text{band}}(x) = \sum_{c=1}^C \sum_{f \notin \mathcal{B}} |\mathcal{F}(x_c)(f)|^2,$$

其中 $\mathcal{F}$ 是 Fourier transform， $\mathcal{B}$ 是任务相关的合理频带集合。例如 motor imagery 常关注 μ rhythm 和 beta band；P300/ERP 任务则可能更关注特定 latency window 内的时域成分。

7.4 功率谱密度匹配

如果攻击者知道或能估计 EEG 的平均功率谱密度，可以要求合成信号的 PSD 接近参考统计：

$$R_{\text{PSD}}(x) = \|\text{PSD}(x) - \bar{P}\|_2^2.$$

这里 $\bar{P}$ 可以来自公开 EEG 数据集、当前任务数据、或模型内部统计的近似估计。

7.5 空间协方差先验

EEG 多通道之间存在空间相关性。可以对通道协方差矩阵加约束：

$$\Sigma(x) = \frac{1}{L} x x^\top \in \mathbb{S}_{++}^C,$$

$$R_{\text{cov}}(x) = d_{\text{SPD}}(\Sigma(x), \bar{\Sigma})^2.$$

$\bar{\Sigma}$ 是参考空间协方差， d_{SPD} 可以是 log-Euclidean 或 affine-invariant Riemannian distance。这类先验对基于协方差特征或 Riemannian geometry 的 BCI 模型尤其自然。

7.6 电极拓扑平滑先验

相邻电极的信号通常有一定空间连续性。如果已知电极图结构 G ，可以使用图拉普拉斯正则：

$$R_{\text{graph}}(x) = \sum_{\tau=1}^L x_{:, \tau}^{\top} \mathcal{L}_G x_{:, \tau},$$

其中 $\mathcal{L}_G$ 是电极邻接图的 graph Laplacian。

7.7 EEG 版 MI 的一个可能目标

如果把 BrainWash 的 MI 思路迁移到 EEG，可以把输入从图像换成 EEG trial：

$$x \in \mathbb{R}^{C \times L}.$$

一个可能的 EEG-MI 目标是：

$$\begin{aligned} \hat{x}_t^i = \arg \min_{x_i} \text{CE}(\text{softmax}(h_t(f(x_i; \theta_{1:T-1}^*); \psi_t^*)), \hat{y}_t^i) \\ + \lambda_{\text{time}} R_{\text{time}}(x_i) + \lambda_{\text{band}} R_{\text{band}}(x_i) + \lambda_{\text{cov}} R_{\text{cov}}(x_i) + \lambda_{\text{graph}} R_{\text{graph}}(x_i). \end{aligned}$$

这些正则项不是 BrainWash 原文使用的内容，而是将其 MI 思路迁移到 EEG/BCI 场景时可以考虑的领域先验。

8 结论

- MI 时攻击者不需要知道旧任务真实样本，但需要访问训练好的模型结构和参数。
- 目标标签是随机采样的 one-hot 类别；输入从随机噪声初始化。
- MI 优化发生在 frozen victim model 上，更新输入，不更新模型。
- 合成样本要让对应旧任务 head h_t 判成采样到的特定 class。
- MI 中的目标标签不是真正投毒给 victim 的错误标签；BrainWash 真正投毒的是当前任务输入 $x_T^i + \delta^i$ ，标签通常保持 y_T^i 不变。
- EEG 中可以构造幅值、时间平滑、频带、PSD、空间协方差、电极拓扑等先验，但没有一个完全等价于自然图像先验的通用标准。